

图像识别技术在航天用塑封器件可靠性检测的应用

摘要

航天用元器件对可靠性的要求极为严格，超声波扫描显微镜检筛选试验是保证元器件在空间环境下不发生失效的有效手段。然而，传统的塑封器件超声波扫描显微镜检技术极大依赖于技术人员的主观感觉和知识经验，识别准确率有限且易发生“误拒”的风险。本文首次利用图像处理和机器学习技术对塑封器件扫描图片进行失效识别，该方法不需要技术人员过多的参与，提高了识别精度与效率，同时具有较强的创新性和现实的研究价值。

塑封器件在空间环境中的应用存在较大的失效风险，塑封分层是元器件十分常见的失效形式，超声波扫描显微镜检技术能够准确的筛选出存在分层的元器件。对此本论文参考国军标等相关标准，设计标红区域面积比率作为失效特征描述子，并利用图像处理的方法提取失效特征。针对失效元器件数据的样本分布不平衡性和普通分类器假设所有分类错误代价一致的局限，本论文引入代价敏感学习机制。通过计算综合调整比，利用下采样的方法使样本分布平衡化，同时使分类器具有代价敏感性。结果表明经过代价敏感和样本分布平衡化处理后，分类器的查准率和查全率均得到了明显提升。此外本论文还对比了几种常见学习器的性能，分析结果知，AdaBoost、支持向量机、PNN 概率神经网络、GRNN 广义回归神经网络均有较好的分类性能，可以用于实际的塑封器件超声波扫描显微图片失效识别中。

本论文根据上述相关工作成果，编写塑封器件声扫失效图像识别工具，实现塑封器件超声波扫描显微图片分割、失效特征提取及失效识别过程的可视化，减轻技术人员的操作压力和认知负担。同时友好的人机交互功能也使得本论文的工作更具实际的商用价值和现实的研究意义。

关键词：航天用塑封器件，超声波扫描，图像识别，代价敏感

Application of Image Recognition Technology in Reliability Test of Aerospace Plastic Packaging Component

Abstract

Aerospace plastic packaging components are in high demand as reliability and scanning acoustic microscope screening test is an effective tool to ensure them work in space environment. However, the traditional ultrasonic inspection technology relies heavily on the technicians' knowledge and subjective feelings. It has a limit recognition accuracy and is likely to happen false rejection events. We first use image processing and machine learning technology to recognize the failure of plastic components ultrasonic images. This method not only doesn't require too much involvement of technicians and improves the recognition accuracy and efficiency, but also has a strong innovation and practical research value.

There is a great risk of failure in the plastic packaging parts work in space environment. Package delamination is a very common failure mode and ultrasonic inspection technology can filter out delamination components. Aiming at the limitations that general classifier assume all the classification error costs are the same and the data exist a certain unbalance problem, we introduce cost-sensitive learning. Calculating the integrated adjustment ratio to balance the sample distribution and making classifier sensitive. The results show that after cost sensitive and balance processing, both the recall and precision improved clearly. In addition we also compared some different classifiers, analyzing the results we find Adaboost, SVM, probabilistic neural network (PNN) and generalized regression neural network (GRNN) have the perfect classification capability.

Finally, basing on the research results, we develop plastic part acoustic scanning image failure recognition tool to realize the visualization of image segmentation, failure features extraction and failure recognition. Reduce the operating pressure and cognitive burden of technicians. In the meantime, the friendly man-machine interaction function also makes the work has practical commercial value and research significance.

Key words: aerospace plastic packaging components, ultrasound scan, image recognition, cost-sensitive

目 录

1 绪论	5
1.1 项目研究背景及意义	5
1.1.1 塑封器件在航天领域中的应用情况	5
1.1.2 塑封器件在航天应用中存在的问题	7
1.1.3 声学扫描技术在塑封器件检测中的应用及存在的缺陷	8
1.2 超声波扫描显微镜检及图像识别技术国内外发展现状	11
1.2.1 超声波显微镜检技术的研究发展及应用情况	11
1.2.2 声扫技术在信号、图像处理和模式识别交叉领域的研究发展	13
1.2.3 超声扫描显微镜系统的研究发展	14
1.3 论文的研究意义与研究内容	15
1.3.1 论文的研究意义	15
1.3.2 论文的主要研究内容	15
1.4 本章小结	17
2 超声波扫描原理及元器件失效形式	19
2.1 扫描式超声显微镜（C-SAM）检测原理	19
2.2 超声波扫描显微镜的扫描模式	22
2.3 塑封器件封装失效形式	25
2.3.1 引线架界面分层	27
2.3.2 芯片界面分层	28
2.3.3 焊板分层	29
2.4 本章小结	30
3 元器件超声波扫描图片失效特征提取	31
3.1 元器件超声波扫描图像的预处理与分割	31
3.2 潜在失效元器件超声波扫描显微图片的筛选	34
3.3 失效特征描述子的设计与提取	34
3.3.1 塑封器件超声波扫描图片预处理	36
3.3.2 元器件失效情形的确定及标红区域面积比率的计算	38
3.3.3 标红区域面积比率的计算	39

3.4 本章小结	41
4 塑封元器件失效识别模型研究	42
4.1 塑封元器件失效特征数据分析	43
4.1.1 失效特征数据的代价敏感学习	44
4.1.2 失效特征数据的类别不平衡性	46
4.1.3 代价敏感分类器综合性能的评价	48
4.2 元器件样本特征数据的预处理	49
4.2.1 代价敏感样本的预处理与数据的分布平衡化	49
4.2.2 元器件失效特征数据的重采样	50
4.3 基于机器学习的塑封元器件失效识别模型研究	53
4.3.1 机器学习模型的选择	54
4.3.2 集成学习 AdaBoost 识别失效元器件	55
4.3.3 支持向量机识别失效元器件	59
4.3.4 神经网络识别失效元器件	61
4.4 各失效元器件识别模型性能的比较	71
4.5 本章小结	72
5 塑封元器件声扫失效图像识别工具的实现	73
5.1 塑封元器件超声波扫描图片读取功能	73
5.2 塑封元器件超声波扫描图片分割、保存功能	73
5.3 潜在失效元器件超声波扫描图片筛选、保存功能	74
5.4 单张塑封器件超声波扫描图片查看功能	74
5.5 单张塑封器件超声波扫描图片处理功能	75
5.6 元器件失效特征的提取与、保存与失效判别	75
5.7 本章小结	75
6 结论与展望	76
6.1 工作总结	76
6.2 工作展望	77
参考文献.....	75

1 绪论

塑封器件由于其具有体积小、重量轻、功耗低、货期短且价格相对较低等优点而被大量应用于航空、航天领域。但是塑封器件绝大部分为商用器件，其在空间环境中的使用存在一定风险。为满足现代空间任务快速发展的需求，保证空间任务的顺利开展，我们必须严格控制塑封器件发生失效的潜在风险。元器件筛选实验是规避失效风险的有效手段。超声波扫描显微镜检能够有效发现大量的导致塑封器件潜在失效的分层、裂纹、空洞、多余物等缺陷，而且是一种无损检测手段，因此在元器件检测实验中被广泛采用。目前国内外对超声波扫描技术和元器件失效原因分析已有大量研究。此外，图像识别技术原理及应用在其它领域也有蓬勃发展。然而，将图像识别技术运用至元器件超声波扫描检测中的研究国内外均没有涉及，本论文首次提出将图像识别技术运用至航天用塑封器件可靠性检测中，并在超声波扫描显微镜检中实现了塑封器件失效自主识别的初步应用。

1.1 项目研究背景及意义

1.1.1 塑封器件在航天领域中的应用情况

近些年来，随着航天技术的迅速发展和半导体微电子器件技术水平的不断提高^[1]，塑封器件，尤其是高性能商用现货（Commercial - Off - The-Shelf, COTS）塑封器件由于其体积小、重量轻、功耗低等优点^[2]而在航天领域逐渐被广泛应用。此外，航天器中大量使用的高可靠宇航级器件的价格比塑封器件高出数倍，而性能却一般要落后 2~3 代^[3]，因此对于性能要求较高的航天设备，宇航级器件往往不能很好的满足要求。此外，相比于对中国禁止出口或限制出口的大量宇航级器件，商用塑封器件更易获取。而且塑封器件拥有较大的存货量，生产周期和采货时间远短于宇航级器件^[4]，故采用塑封器件能大幅缩短产品设备的研制和生产周期。综上所述，塑封器件具有体积小、重量轻、功耗低、性能优、采购容易、时间成本与采购成本均较低等优点，因此塑封器件在航天领域中的应用具有较大潜力。

目前商用塑封器件已经在多个空间项目中成功使用^[5]。国外早在 20 多年前就已经开始尝试在卫星上使用塑封器件。例如美国 ARGOS-先进研究和全球观测卫星、南非 SumbandilaSa-对地观测技术试验微卫星、德国 BIRD-双频段红外遥感探测卫星、STEREO(Solar Terrestrial Relation Observatory)、GLAST(Gamma-ray Large Area

Space Telescope)、LAT(Large Area Telescope)等。

2001 年德国发射 BIR0 小卫星, 在运行的 20 个月中, 其搭载的由塑封器件集成的星载计算机包括实时操作系统和控制软件系统工作正常^[6]。南非第一颗自主研发的 SumbandilaSat 小卫星其内部采用瑞萨科技公司的 SH-4 处理器 (SH7750)、SRAM (CY7C1069) 处理器和爱特公司的一次性可编程熔断 FPGA 等 COTS 塑封器件, 从 2009 年 9 月运行至 2011 年 7 月, 平均每天的重启次数仅为 1.04 次^[7]。Surrey 大学发射的小卫星中, 大量使用商用塑封器件。例如, 在其发射的 UoSAT-12 卫星中使用了商用 GPS 接收机, 成功获取了大量的关于商用塑封器件应用的数据^[8]。这些结果为商用器件在星载计算机中的使用奠定了坚实的技术基础。

NASA 每年有近千万美元支持塑封器件在航天领域的应用这一项目的研究^[9], 包括 ARC, GRC, Aerospace Corp, NAVSEA, ESA 和 NASDA 等。NASA 专门推出的器件和封装计划, 即 NEPP 计划, 由多家权威机构参与, 其目标是评价最新上市的商用器件, 新型电子、光学器件以及封装技术的辐射敏感度和可靠性, 该项目直接为 NASA 在空间环境下采用新型电子器件而避免发生失效风险提供技术支持。此外 NASA 还于 2002 年 2 月 26 日发布了商用塑封器件在空间环境中使用的白皮书, 书中政策指明: “倘若对特定应用的器件在热、机械、辐照方面进行彻底评估确认可以满足任务需求的话, NASA 哥达德航天中心允许在航天器中使用塑封微电子器件……”。

90 年代初, 国内也逐步开始了商用器件空间应用的探索。北京控制工程研究所首次提出将未经抗辐射加固的芯片用于小卫星中^[10], 并于 1999 年在“实践五号”飞行任务中取得了成功。1999 年 5 月在发射的神舟四号飞船中, 微重力流体电控系统采用的热电偶放大器 AD595C 为商用器件。该器件对性能指标的要求较高, 而军品级元器件中并没有能够满足质量等级要求的器件。相对于完全采用航天级电路板, 商用器件的采用使得电路板体积小、一致性好、精度高和功耗低, 同时完全能满足系统高性能的需求^[11]。神舟七号伴随卫星、天空一号空间科学与试验任务中, 其关键核心设备均使用了商用塑封器件, 并取得了飞行任务的圆满成功。

实践表明: 采用塑封商用器件不仅能够很好的满足空间任务的要求而且由于其本身具有的优点, 使空间系统的综合性能得到了较大的提高。随着商用塑封器件性能的日益提高, 在我国航天重大任务和商业航天星座建设中, 已经开始大批量使用塑封商用器件以满足现代空间任务快速发展的需求。

1.1.2 塑封器件在航天应用中存在的问题

一般的塑封器件均为 COTS 器件，是以满足在地面环境下能正常工作为目的而设计生产的，因此其可靠性和抗辐射能力相对较低，若应用于航天领域将存在一定的风险，这也使得塑封器件在航天领域的应用受到了一定的限制^[12]。

塑封器件，在空间环境中要面临粒子辐射和热环境的考验，由于其抗辐射能力差，适用温度范围窄。因此，将其应用于空间环境中可能会存在多种不同程度的失效情况^[13]。

(1) 塑封器件工作温度区间比较窄，性能受温度变化的影响较大，其塑封层在高温时会软化，低温时容易变脆；当工作在额定温度范围之外时可能导致封装材料的快速退化、导线弱化。此外，硬模机械过压，将成指数倍地加速失效^[14]。

(2) 随着半导体制造技术的不断进步，塑封器件的集成度越来越高，其尺寸也更小、工作速度也更快，对高能粒子辐射影响也将更加敏感，空间辐射效应更加突出。此外，其发生单粒子事件的概率也逐渐升高。

(3) 塑封器件的模压材料通常与硬膜相连，该材料中可能含有离子，该材料也可能成为影响硬模辐射敏感性的二次发射源。同时，塑封器件由氮化物层进行钝化，这些都将导致塑封器件对辐射总剂量效应更加敏感。

(4) 许多塑封器件的内部引线一般为金丝或铜丝，与芯片的键合界面为金-铝键合或铜-铝键合。特别是铜-铝键合容易受到铜氧化物污染或损伤，而且焊接质量也一般较差，在温度漂移、机械冲击或振动过程中容易发生失效。

(5) 塑封器件塑封分层现象比较普遍，这将导致器件散热不好而直接烧毁器件；此外，在分层处容易吸收水汽或者聚集结晶水，水汽既会腐蚀芯片又会影响电路性能而造成电路失效。同时，在回流焊高温焊接时，吸收的水汽或者聚集的结晶水将受热膨胀，造成键合引线断裂、芯片损伤，甚至塑封料开裂引发“爆米花”效应，这将直接损坏元器件^[15]。

(6) 总剂量效应 (Total Ionizing Dose, TID)：空间带电粒子入射到物体，即吸收体时，将全部或部分能量转移给吸收体，这些被转移的能量被称为吸收体吸收的辐射总剂量。当吸收体为星载电子元器件时，它们将受到总剂量辐射损伤，该现象即为总剂量效应^[16]。总剂量效应是一种累积效应，高能粒子对元器件的辐射损伤是随时间的积累而逐渐形成并加重的。由于高性能塑封器件集成度高、体积小，且表面由氮化物钝化，因此其对总剂量效应将更为敏感。

(7) 单粒子效应(Single Event Effect, SEE): 空间高能粒子轰击星载电子器件, 导致电子器件逻辑功能翻转或器件损坏的事件^[17]。根据单粒子效应机理的不同, 可将其分为单粒子锁定(Single Event Latch-up, SEL)、单粒子翻转(Single Event Upset, SEU)、单粒子栅击穿(Single Event Gate Rupture, SEGR)和单粒子烧毁(Single Event Burnout, SEB)等多种类型。由于塑封器件体积小、集成度高, 因此每个记忆单元的尺寸也相对较小, 引起翻转所需的临界电荷也小, 故其对单粒子翻转事件更为敏感。

(8) 充放电效应: 航天器遇到等离子体时与等离子体发生相互作用, 导致航天器带电, 该事件称为航天器充放电效应。当航天器充电达到一定程度后, 所产生的强电场将造成器件击穿, 放电所产生的电磁辐射也会干扰到航天器上各种电子设备的正常工作, 从而引发航天器的失效或故障^[18]。

在上述元器件的各种失效模式中, 充放电效应和粒子辐射效应是导致航天器发生异常的主要原因。而塑封器件由于其集成度高、外壳没有防护措施, 因此对粒子辐射更加敏感。相较于粒子辐射所导致的失效, 分层现象是塑封器件发生失效的主要原因, 本文将重点讨论塑封器件分层失效缺陷。

为保证航天任务的顺利完成, 我们必须采取一定措施保证元器件尤其是塑封元器件的可靠性。目前国内外元器件可靠性质量保证技术主要包括: 补充筛选(二次筛选, 简称二筛)、失效分析(Failure Analysis, FA)、破坏性物理实验(Destructive Physical Analysis, DPA)、和结构分析(Construct Analysis, CA)。其中补充筛选是对元器件进行空间适应性筛选必不可少的关键环节和有效方法。元器件补充筛选主要试验包括: a. 外观检查; b. 声学扫描显微镜检 CSAM (C-mode Scanning Acoustic Micro scope); c. X-射线检查; d. 温度循环试验; e. 老化筛选试验; f. 振动冲击筛选试验; g. 湿热试验; h. 应力加速试验^[19]。

1.1.3 声学扫描技术在塑封器件检测中的应用及存在的缺陷

相关研究表明, 塑封元器件的分层缺陷比较普遍, 由此而影响塑封器件的可靠性、散热、抗辐射能力和寿命等, 甚至会产生其它的失效机制。只有当塑封器件在没有分层或只有轻微分层时, 才可以被用于空间任务。对于塑封元器件的二次筛选, 超声波扫描检查与其他几种筛选方法相比能够最有效的发现元器件潜在问题^[20], 而且在检测过程中, 该技术不会对元器件本身产生损伤, 是一种无损检测的方法^[21]。因此, 超声波扫描显微镜检, 作为检测塑封器件内部界面是否分层的主要试验方法, 常被用于塑封器件的可靠

性检测中。表 1.1 为中科院空间应用中心可靠性保障中心一段时间内对塑封器件做超声波扫描显微镜检测的结果。

表 1.1 各元器件失效情况统计

元器件型号	失效元器件数量	缺陷率
89HTXXX	1	20%
AD9XXX	0	0%
BSSXXX	0	0%
LTC2XXX	0	0%
LTC29XXX	3	7.7%
MAX30XXX	8	100%
MBRS3XXX	54	6.5%
MSP43XXX	0	0%
Si826XXX-背面	56	91.8%
Si826XXX-正面	234	79.3%
USBXXX	2	33.3%

从上表中能明显发现某些元器件如 MAX30XXX、Si826XXX 存在大量的失效，其失效率在 90%以上，若不经筛选试验而将其直接应用于空间任务中将存在较大的风险。通过超声波扫描显微镜检技术能发现大量存在潜在失效风险的塑封器件，有效保证空间任务的顺利开展，因此该技术是一种有效的检测手段。

超声波扫描显微镜检技术在检测塑封器件内部空洞、裂纹和分层缺陷时是一种方便、无损且准确的技术。其主要原理为：超声波转换器产生不同频率的超声波^[22]，利用回声定位法检测元器件内部缺陷^[23]。通过对塑封器件进行声学扫描，可以有效地识别批量元器件的塑封和制造工艺缺陷^[24]。由于该方法是一种非破坏性的试验方法，能够有效检测塑封器件内部缺陷而不损坏器件，同时与其他手段相比，如 X 射线无损检测，超声波显微镜检具有更高的灵敏度，可以检测到更细微的缺陷，且能获得高对比度图片和重要信息而被广泛采用。超声波显微镜检不仅有助于降低整个产品中出现缺陷的风险，还能提高产品的可靠性，其在帮助用户评估产品质量方面发挥着重要作用。但是，现有的超声波显微镜检技术均需要检测人员参考国内外发布的试验技术标准，并依赖自身的专业知识、直觉和经验，根据塑封器件超声波扫描图片中存在的某些明显特征判别元器件是否失效。因此，现有的检测技术存在以下几个明显的问题和缺陷：

(1) 超声波扫描显微镜系统的初始设置存在一定的不确定性。对塑封器件进行超声波扫描时，针对噪声信号的干扰以及成像的要求，需要人为确定和调整阈值的大小，只有当反射波信号超过一定的阈值时系统才会判定该信号是失效信号并将图片中的对应区域标注为红色。而该阈值的设定需要参照一定的标准并依赖技术人员的经验，它并

不是一个明确给定的值，存在一定的模糊性和不确定性。因此，在依据塑封器件超声波扫描显微图片中标红区域的位置和标红面积来判别元器件是否发生失效时，可能会存在因阈值设置不合理而出现“误拒”或“误受”元器件情况的发生。

(2) 技术人员对塑封器件内部材料和结构缺少明确、全面的了解而对反波信号产生误读，存在“误拒”元器件的风险。由超声波扫描显微镜检原理可知，当入射波从声阻大的物体进入声阻小的物体时，在界面处相位总是发生反转。如果失效分析工程师对检测元器件封装的内部材料与结构并没有全面而准确的了解，依照自身的直觉和主观意志来判别元器件的失效情况，这将很有可能对反波信号出现误读。即在塑封器件超声波扫描显微图片中可能存在某处标红区域是由半导体本身的结构和材料决定的，并非真正的分层或空洞缺陷，而技术人员将其误认为是缺陷信号，存在“误拒”的可能。

(3) 现有的缺陷判据受技术人员的经验和主观意志的影响较大，在面对同一张失效特征并不是十分明显的塑封元器件超声波扫描图片时，不同技术人员拥有不同的经验、理解和观察角度，因此对其是否发生失效的判别可能会给出不同的结论，有时甚至需要通过会议讨论确定，这样既增加了时间成本，延缓了工作任务的进度，同时也存在“误拒”和“误受”的可能。例如：技术人员在根据塑封器件超声波扫描显微图片判别其是否发生失效时，主要参考国军标：《军用电子元器件破坏性物理分析方法》(GJB4027A-2006)^[25]、《微电子器件试验方法和程序》(GJB548B-2005)^[26]；美军标：《电子、电磁、机电配件破坏性物理分析》(MIL-STD-1580B)^[27]和美国航空航天局技术标准：《塑料封装微电路 (PEM) 选择、筛选和鉴定说明》(PEM-LNST-001)^[28]。其中 GJB4027A-2006 项目 1103 章节 2.4.4f 条：红色区域位于元器引线引出端焊板与模塑化合物的分界面处，该区域分层面积超过其后侧区域面积的 50% 属于标准缺陷，需要拒收。GJB4027A-2006 项目 1103 章节 2.4.4g 条：引脚从塑封完全剥离（上侧或后侧）属于标准缺陷，需要拒收。该国军标中提及的 50% 和完全剥离这两个量词，极大的依赖于检测人员的目测判断、主观感受和工作经验，对于缺陷特征并非十分明显的元器件极易出现“误受”与“误拒”的情况。

(4) 技术人员根据超声波扫描图片肉眼判别元器件是否发生失效，其时间成本和采购成本均较高。对于大量的元器件检测任务，技术人员需要对其超声波扫描图片一张张的进行观测确认，工作量较大且耗时，另外技术人员也容易出现因工作疲劳导致工作效率下降的情况。对于存在争议的元器件判别结果，有时需要会议商讨，这也延缓了任

务进度,增加了时间成本。在实际的元器件失效判别中,对于不确定是否失效的元器件,技术人员往往采取从严判别的措施以减少的“误受”的风险,但这也增加了“误拒”的风险,即某些并未发生失效的元器件可能也会被作为缺陷器件处理。此外,根据中国航天科工集团公司标准元器件筛选技术条件 QJB 103A-2010^[29]第一部分 2.11 条:国产元器件 PDA 大于 5%,进口元器件 PDA 大于 10%时,该批元器件不合格。这将导致同批次中许多并未失效的元器件也被视为不合格,而需要采购一批新的元器件重新进行检测,增加了采购成本、延缓了工作进度。

从根本上说,现有的塑封元器件超声波扫描显微镜检方案,主要依赖于技术人员的经验、主观意志,根据现有的判别准则来肉眼判断元器件是否发生失效。这种传统的方法是导致元器件检测周期长,成本高,容易出现“误拒”和“误受”情况的根本原因。因此,我们很有必要寻找一种新的技术方案,在保证元器件缺陷识别准确率的前提下,还能不依赖技术人员的知识经验和主观意志,甚至不需要人为干涉,利用较少的时间成本和采购成本来判别元器件是否发生失效。

图像识别技术已广泛应用于医疗、工业、交通、农业等各个领域,在工业应用方面,目前对于人脸识别、无人驾驶等技术已经有了非常深入的研究。国内外许多大学及科研院所所以发表了大量高水平的学术论文与研究报告,其研究成果也引起了学术界和工业界的广泛的讨论和极大关注。

在上述理论和技术的发展背景下,本文创新性的提出了一种的根据塑封元器件超声波显微镜检图片,利用图像识别技术来自主识别元器件是否发生失效的方法。通过图像识别技术,让机器自主判别元器件是否存在缺陷,这一方法能大大提高工作效率,缩短元器件的检测时间,加快产品的研发和生产进度,降低元器件的采购成本,同时还能提高元器件检测的正确率,减少误判的风险。因此,将图像识别技术应用于塑封器件超声波扫描显微镜检中具有重要的理论价值和现实意义。

1.2 超声波扫描显微镜检及图像识别技术国内外发展现状

1.2.1 超声波显微镜检技术的研究发展及应用情况

超声波技术的应用最早可追溯至 1912 年泰坦尼克号沉没事故^[30],当时人们利用超声波回波技术来确定其沉没的位置。随后,在第一次世界大战期间,Pau Langevin 成功利用超声波定位技术来探测水下潜艇,并由此而发展出了声呐系统(Sonar-Sound Navigation and Ranging)。二次世界大战时,高频率超声技术研制成功,并将其应用

于工业的无损探伤检测，即利用超声波来检测材料或产品的缺陷。在此期间出现的脉冲回波探伤仪器成为超声波检测技术发展中的重要标志。此后人们又将超声波技术应用于清洗、焊接等领域^[31]。战争结束后，用于军事上的许多超声波检测研究成果被公诸于世，很快人们就发现了其在医学上的应用价值，并于 20 纪 50 年代初研制出了真正用于医学诊断的超声装置。60 年代，压电陶瓷材料可以作为超声换能器的发现以及电子技术、计算机技术和信号处理技术的蓬勃发展为声成像的研究提供了理论和技术的支持，这使得超声波检测技术重新恢复了生机。1974 年美国斯坦福大学的 Lemons 和 Quate 开发了世界上首台扫描超声显微镜成像系统^{[32], [33]}，并成功用于微细结构的扫描结构检测。此后，大量商业级超声波扫描显微成像设备问世，并逐渐形成了几种较为成熟的检测方法。超声波扫描显微镜检技术开始广泛应用于医学诊断、工业材料的检测中。现在，超声波扫描显微镜检技术已在多个领域中发挥着重要作用。

在元器件可靠性检测领域，利用超声波扫描显微镜检测塑封器件内部缺陷这一研究方向，国内外已经产生大量高水平的研究成果。黄娇英等人通过分析元器件存在的各种缺陷类型，并结合现有的塑封器件检测标准，提出了一种新的塑封器件超声波显微镜扫描检测的方法，即利用 A-SAM 和 C-SAM 分别对塑封和重要界面进行检测，并只关注元器件三个顶部界面和两个底部界面超声波扫描情况。与传统技术相比，大大缩短了检测时间，提高了检测效率^[34]。Y Chen, P Li 通过对塑封器件超声波扫描显微图片进行分析，总结了三种常见的塑封器件失效形式，并对其失效机理进行了探究^[35]。Y Liang, S Zhang 利用 A-SAM、B-SAM、C-SAM 并结合 X 射线检测技术对 TSSOP 封装类型的存储器缺陷进行检测，总结了一种塑封器件分层缺陷检测的通用方法，与传统方法相比取得了较好的效果^[36]。Y Qiu, S Zhang 通过超声波扫描显微镜检技术对塑封器件管脚分层案例进行了研究，分析总结了根据超声波扫描显微图片和波形对不同封装元器件管脚分层检测的方法^[37]。G. Kamalaakar, Mukesh Kumar 等人详细介绍了一种利用超声波扫描显微镜技术来检测筛选 COST 器件的方法，以确保其在空间环境下的可靠性^[38]。P Mario, M Josef, I Michael 对超声波扫描显微镜检技术及其原理进行了详细的研究，并用塑封器件的失效案例阐明了该技术与其它无损检测技术相比的优越性^[39]。Liyuan Liu, Enliang Li 等人通过对两种不同的塑封类型元器件的分层缺陷进行研究，提出了一种根据超声波扫描显微镜检技术判别元器件是否发生失效的方法，为塑封器件可靠性检测提供了一定的参考依据^[40]。陈章涛，潘凌宇总结了近几年塑封器件 DPA 试验中出现的各

种失效类型，并重点对塑封器件内部界面分层以及分层产生的原因、危害进行了讨论。同时还论述了超声波扫描显微镜检技术对内部界面分层的辨别、原理及其相关试验标准，提出了塑封器件在型号产品中的使用建议^[41]。

在医学领域中，奥地利科学家 Dussik 首次将超声波检测技术应用于医疗诊断中，并于 1942 年采用透射式一维示波法探测颅脑，用以获得脑部的图像，同时根据脑室内部几何形状的偏移来检测脑部肿瘤。随后 Ludwig 和 Struthers 将这种超声波无损检测仪器应用于胆结石的临床检测中。1950 年，美国的 J. J. Wild 等人采用脉冲反射式示波法获得了脑肿瘤标本的反射波，从而奠定了 A 型超声诊断的基础。与此同时，用超声波对乳腺肿瘤、肾肿瘤、子宫、胎儿及眼睛等病症进行诊断的技术也相继先后提出。

在材料厚度及缺陷检测领域，近年来已有不少用高频超声波测量材料特性的新方法，并用于超声显微成像。Good 等人^[42]采用 70MHz 超声波测量 100 μm 厚的生物薄层的厚度，实现了薄膜微观特性的形貌观察。Raum 等人^[43]通过扫描超声显微镜获得了多层组织薄层材料的声阻抗图。Tohmyoh 等人^{[44], [45], [46], [47]}建立了干耦合式扫描超声显微镜，并提出将超声共振谱用于测量薄膜材料的声阻抗、密度和声速的技术方法。Kannajosyula 等人^[48]实现了两层材料的纵波声速和厚度的同时测量。

1.2.2 声扫技术在信号、图像处理和模式识别交叉领域的研究发展

目前国内外已有大量学者研究超声信号本身的特征提取与挖掘^{[49], [50], [51]}。D' Orazio 等人^[52]根据超声波信号提出了正则化法则对超声信号进行预处理，然后采用三层神经网络同时实现了缺陷区域的分割与识别。Sambath 等人^[53]将小波变换技术 (wavelet transform, WT) 应用于原始超声回波以提取关键特征，然后通过训练三层神经网络实现了对缺陷的分类和识别。Zhang 等人^[54]选取合适的 SSR 算法和超完备字典用于超声回波信号的表征，并将其应用于缺陷的检测中。

此外，基于超声波扫描显微图像的缺陷检测算法的研究已比较成熟，应用也较为广泛^[55]。Kumar 等人^[56]利用 Gabor 小波特征检测复杂纹理背景下的缺陷。Otsu 方法是根据图像中灰度级的分布来自适应地分割出缺陷区域^{[57], [58]}。HT Lee 根据两层涂敷的点焊样本超声波扫描图片提取出焊点面积、焊点最长轴线与最短轴线等几何参数，并将其作为神经网络的输入，实现对焊点质量的自动评估。模型的评估精度能达到 95% 以上，此结果令人满意^[59]。M Fan, L Su 等人开发了一种利用超声波扫描显微镜检测焊料凸块的智能系统。该系统根据超声波扫描图像的梯度矩阵提取统计特征，并基于模糊支持向量

机(F-SVM)算法对焊料的缺陷实现分类。实验结果表明智能检测系统能够十分有效的对高密度焊料凸块缺陷进行检测,而且 F-SVM 算法能够达到较高的识别精度^[60]。然而,目前的大多数缺陷检测算法都难以兼备高效率和高精度。近年来大量对视觉注意力和图像显著性模型的研究表明,图像中存在大量的冗余信息,真正有用的信息只占到图像中比较小的一部分,例如小波分析的思想就认为图像中的低频信号包含了大量信息,而高频信号所包含的有用信息就很少。与之相似,在超声波扫描图像中,缺陷只占到很小的一部分区域。因此有必要通过图像处理算法去掉图像中大量冗余信息,将注意力集中处理最有可能包含缺陷的小部分区域,这样可以保证同时提高缺陷检测的效率和精度。同时,这也是本论文重点研究的方向之一。

1.2.3 超声扫描显微镜系统的研究发展

目前国内外几家公司和科研院所已经有面向电子芯片等检测的超声扫描显微镜系统。中国电子科技集团第四十五研究所于2010年左右开始了面向芯片检测的系统研究,并推出了部分型号的样机。例如超声波扫描显微镜 C-300 其扫描精度为 $1\mu\text{m}$,速度为 1m/s ,超声波发射接收器带宽为 $5\sim 500\text{MHz}$ 。扫描模式包括:A、B、C 三种,同时还提供了一些图像量化等软件分析工具。

与国内研究现状相比,国外对超声波显微镜系统整机开发的研究要相对成熟,尤其是美国、德国。国外许多大学和科研院所也开展了大量有关超声波扫描显微镜集成电路的评价研究和探索工作,并积累了丰富的经验和成果。此外,结合半导体行业的要求,超声波扫描显微镜的研究包括各个方面,如采用先进的控制策略与控制算法,提高显微镜扫描的精度、速度和扫描范围,采用先进的信号处理技术,并结合材料的声特性,提高超声波扫描显微镜的分辨率等。越来越多生物、材料领域的研究人员通过超声波扫描显微镜来做一些前沿的研究。德国 PVA 公司的 TePla—SAM 系统是目前世界上功能最全面的超声波扫描显微镜,它应用 KSI 公司的超声技术,从超声波发射接收装置、超声波探头到高速 AD 采集卡均自行研发生产,换能器可以从 3MHz 到 2GHz 任意选择,以满足不同场合的不同需求。另外,该系统根据回波信号,在显微成像的同时显示材料的不均匀性密度差异、张力和分层。另外,其他几家公司产品也较为成熟,如 SONIX 很早就开始超声波扫描显微镜的研制,奥巴斯对超声波扫描显微镜也有非常深入的研制等,在此就不一一列举。超声波扫描显微镜应用广泛,从集成电路检测到高性能先进材料、飞机引擎的检测等,超声波扫描显微镜技术的发明为众多领域的研究发展打下了坚实的基

础。

1.3 论文的研究意义与研究内容

1.3.1 论文的研究意义

目前国内外对超声波扫描显微镜检技术的研究已相当充分，而且许多著名大学和科研院所已经发表了多篇高水平、高质量的学术论文和研究报告。该技术在医疗诊断、材料内部结构的分析研究、无损检测等方面都得到了广泛的应用。在可靠性检测领域，利用超声波扫描显微镜检技术发现塑封器件内部缺陷，将其应用于元器件可靠性试验和筛选这一领域的研究成果也多如牛毛。此外，学术界和工业界利用该技术与图像识别领域进行交叉，也已经产出了大量有实用价值的研究成果。图像识别技术能够根据图像中的某些统计特征，通过机器学习来自动实现样本的识别分类。该方法不需要人为干涉且能达到较高的识别准确率，拥有长远的研究前景、重要的研究价值和广阔的应用空间。

然而，在塑封器件缺陷检测领域，国内外现有的工作大多都是利用超声波扫描显微镜检技术分析元器件出现缺陷的根本原因和机理。又或是研究元器件缺陷的种类以及如何避免元器件失效的发生。又或是研究如何在传统的塑封器件检测方法上进行改进，以提高检测的效率和精度，并对现有的技术标准提出改进的意见和建议。上述提及的这些研究均需要依赖技术人员的经验知识和主观意识，并参考现有的技术标准来对塑封器件的超声波扫描显微图片进行判别分析。此种方法耗时费力，并且对于特征模糊的超声波扫描图片的判别存在“误拒”或“误受”的可能。目前，国内外还并没有将图像识别技术引入至塑封器件超声波扫描显微镜检应用中的相关研究报告和论文。因此，本论文研究的方向具有一定的创新性和现实的研究价值。

1.3.2 论文的主要研究内容

本论文以有关塑封器件失效原理、失效分析和判别标准以及超声波扫描显微技术在元器件可靠性检测和其他领域中应用的研究成果为基础，在现有的塑封器件超声波扫描显微检测、图像处理和图像识别的理论框架下，将图像识别技术与塑封器件超声波扫描显微镜检技术结合，提出了一种新的航天塑封器件可靠性检测技术，实现对塑封器件失效情况的自主判别。该技术根据塑封器件的超声波扫描显微图片，结合现有的塑封器件超声波扫描检测失效判别准则，人为设计元器件失效特征描述子，利用图像处理的方法提取并量化超声波扫描图像的失效特征，最后将这些量化特征作为输入，利用如神经网络、决策树、SVM 支持向量机、集成学习等机器学习算法实现塑封器件是否存在失效的

自主判别。最后对比传统的识别方法，评估图像识别技术在塑封器件超声波扫描显微镜检技术中的可行性和先进性。具体的研究内容如下：

（1）塑封器件失效标准的研究分析

查阅有关塑封半导体集成电路声学扫描显微镜检查的标准，根据现有的试验标准，观察总结塑封器件失效判别准则在超声波扫描显微图片中的表现形式，以及不同失效类型反映在超声波扫描图片中各自表现形式的特点，分析各类失效塑封器件超声波扫描图片的异同。

（2）设计塑封器件失效特征描述子

根据上述对塑封器件不同失效类型在超声波扫描显微图片中表现形式的分析总结，结合现有的检测标准人为设计特征描述子，提取失效塑封器件超声波扫描图片的统计特征。

（3）利用图像处理技术提取并量化特征描述子

利用图像处理技术量化从塑封器件超声波扫描显微图片中设计所得的特征描述子。为减轻技术人员的工作量，实现失效元器件的自主识别。

（4）利用机器学习算法自主识别塑封器件是否失效

根据上述塑封器件超声波扫描显微图片量化后的特征，利用机器学习算法对其进行自主判别。如将塑封器件超声波扫描图片中提取出的缺陷面积、缺陷长度和缺陷区域的形心坐标作为分类器的输入，根据输出结果判别其是否失效。我们可以选择多种机器学习算法，分别对元器件样本集进行判别，比较和评价各种算法的识别精度和性能。并选择性能最优的算法对元器件失效情况进行自主判别。

（5）根据以上工作成果编写塑封器件超声波扫描图像识别工具，实现塑封器件失效判别过程的可视化

根据塑封器件超声波扫描显微图片利用图像处理技术提取失效特征，并通过训练好的机器学习模型实现塑封器件失效情况的自主识别。根据上述这些工作开发元器件失效自主识别工具，并将塑封器件元器件超声波扫描显微图片的失效识别过程全部以图形用户界面的形式展现，以实现人机的友好交互，同时减少技术人员的操作和认知负担。元器件失效自主识别工具的开发也使得本文的工作更具商业实用价值。

本论文各章节主要的研究内容及其相互间的组织关系如图 1.1 所示。

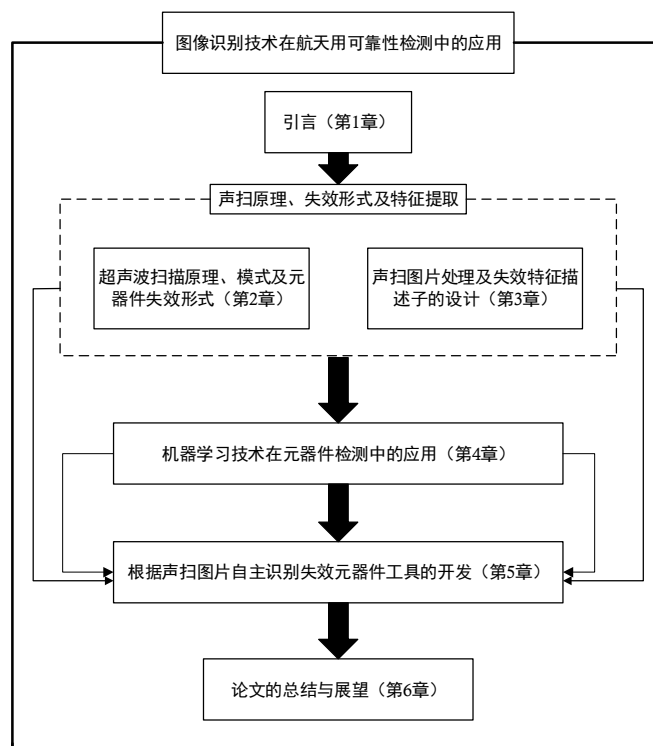


图 1.1 论文研究内容即相互之间的组织关系

第 2 章主要介绍了超声波扫描显微镜检原理、常用的几种扫描模式以及塑封器件的封装缺陷。第 3 章详细描述了塑封器件超声波扫描显微图片失效特征描述子的设计过程，并给出了利用图像处理技术提取特征描述子的具体方法。第 4 章主要利用机器学习的方法，设计了不同的网络结构对元器件超声波扫描显微图片进行失效识别并对其识别的精度进行了分析比较。第 5 章通过结合前两章中塑封器件超声波扫描显微图片图像处理、失效特征提取技术与机器学习自主判别失效元器件的方法，编写开发塑封器件超声波扫描显微图片失效识别工具，并对识别工具的功能和使用进行了详细的介绍。

1.4 本章小结

本章主要内容主要包括以下几部分：

1. 介绍塑封器件在航天领域的应用广泛，但空间环境下塑封器件存在多种潜在的失效风险。说明了避免失效的各种措施，同时指出塑封器件超声波扫描显微镜检是避免失效的有效手段。

2. 介绍超声波扫描显微镜检技术国内外的的发展情况，以及其在图像处理、模式识别等交叉领域的应用情况，指出将图像识别技术应用于塑封器件超声波扫描显微镜检国内外并无类似研究，明确了本论文的创新点。

3. 分析超声波扫描显微镜检技术在塑封器件可靠性检测中的应用情况，发现目前该

技术大量依赖技术人员主观意志和经验，且存在时间成本和采购成本较高等缺陷。

4. 针对目前超声波扫描显微镜检技术存在的不足和缺陷，明确了论文的研究意义思路，具体的研究内容及利用图像识别技术识别失效塑封器件的具体研究方案。

2 超声波扫描原理及元器件失效形式

近年来，电子技术、材料以及半导体行业的飞速发展对元器件的性能、成本和可靠性都有了更高的要求。其中塑封器件由于其体积小、重量轻、封装材料具有良好的电性能、热性能以及机械性能，同时也能较好的满足高可靠、低成本的要求因此被广泛使用。根据有关调查显示塑料封装的电子器件占整个封装材料市场的 95%以上^[61]。

然而，由于树脂封装是非气密性封装，其对外界环境的耐受力并不是很强，尤其是潮气的侵入往往能对器件的可靠性产生极大的影响，造成元器件的分层缺陷。对于工作温度很高的塑封功率器件，其分层问题相较普通元器件更易产生，而且在湿气和高温的协同作用下分层也更容易扩展，因此塑封功率器件对湿热更为敏感，分层失效问题更加突出。

超声波扫描显微镜检技术对塑封器件的分层问题的检测十分有效，通过显微镜检绝大多数分层失效器件能被筛选剔除。本章主要介绍了超声波扫描检测的原理、元器件出现分层失效的原因以及超声波扫描显微镜检技术在塑封器件检测中的应用情况。

2.1 扫描式超声显微镜（C-SAM）检测原理

超声波扫描显微镜是一种非破坏性的无损检测仪器，其可以在不必破坏元器件封装的情况下探测到内部的分层、空洞和裂缝，并且拥有类似 X-Ray 的穿透功能，可以找出问题发生的位置。其成像原理主要为：利用压电陶瓷材料的逆压电效应超声波换能器通过将高频电能转换为机械能从而产生固定频率的超声波。由于超声波是机械波，所以超声回波中可以反映出被测器件材料的几何、力学特性以及缺陷信息。由于不同的材料和介质拥有不同的声阻抗（常见材料的声阻抗见表 2.1），当超声波传输至两种材料的分界面时，其在界面上会发生反射和透射，而反射和透射的比例由两种材料的声阻抗决定^[62]，声阻抗愈大时声波传导性愈佳，反之则愈差。超声波换能器通过压电陶瓷材料的正压电效应将反射波转换为电信号，扫描显微镜系统通过对电信号进行处理，生成反射界面的形貌图样和反射波形图，根据形貌图样及波形图技术人员可以观察材料的内部结构。

表 2.1 常见材料声阻抗

材料	声阻抗 $z(kg / m^2 s * 10^3)$	材料	声阻抗 $z(kg / m^2 s * 10^3)$
水	1.48	环氧塑封料	2~3.5
硅	20.04	铜	41.83
环氧树脂	2.7~3.6	合金 42	45
玻璃	15	空气	0

在利用超声波进行检测时，超声波实际是存在非线性行为的^[63]。这里假设超声波入射至材料界面处发生反射的过程为线性系统，因此通过褶积法，反射波与入射波的关系可用公式（2.1）表示^[64]。

$$S_R(t) = \int_0^\infty P_R(x) S_T\left(t - \frac{2x}{v}\right) dx \quad (2.1)$$

上式中， $S_R(t)$ 为反射波； S_T 为入射波； x 为入射波的传输距离； v 为超声波的传输速度； $P_R(x)$ 为反射系数。反射系数的大小取决于两种材料的声阻抗，声阻抗是表征材料对声波吸收的物理量，其值为声波在传输介质中的速度与介质密度的乘积，如式（2.2）所示。

$$Z = \rho \cdot c = \sqrt{E \cdot \rho} \quad (2.2)$$

上式中， ρ 为材料密度； c 为声波在介质中的传波速度； E 为材料的杨氏模量。

假设 Z_1, Z_2 分别表示入射区（材质 A）与穿透区（材质 B）的声阻抗，当超声波在射入两材料分界面时与分界面间存在一定的角度，我们记入射波的入射角为 φ ，反射波的反射角为 φ_t 则反射系数 P_R 表示为^[65]：

$$P_R = \frac{Z_2 \cos \varphi - Z_1 \cos \varphi_t}{Z_2 \cos \varphi + Z_1 \cos \varphi_t} \quad (2.3)$$

在实际的超声波扫描中，我们一般让超声波垂直入射，此时可认为入射角 φ 与反射角 φ_t 的角度均为 0，故反射系数 P_R 的计算公式如式（2.4）所示。

$$P_R = \frac{Z_2 - Z_1}{Z_2 + Z_1} \quad (2.4)$$

根据上述原理可知，当超声波传递到不同材质的界面时，将会产生下列三种形态的声波反射波形：

形态 1：当 $Z_1 < Z_2$ 即 $P_R > 0$ 时，反射波为正相；

形态 2：当 $Z_1 > Z_2$ 即 $P_R < 0$ 时，反射波为负相；

形态 3：当 $Z_1 = Z_2$ 即 $P_R = 0$ 时，无反射波。

由表 2.1 可知环氧塑封料的声阻抗 $Z_1 \approx 2.2 \text{ MRayl}$ ，空气的声阻抗 $Z_2 \approx 0$ 。故根据公式（2.4）计算反射系数 $P_R \approx -1$ ，即入射波发生相位反转并几乎全部反射。超声波在不同介质层的传递现象以及使用超声波扫描显微镜检测塑封器件的示意图如图 2.1 所

示。




图 2.1 超声波扫描典型界面反射波示意图




图 2.2 声波在不同介质层中的传递现象

使用超声波扫描显微镜检测塑封器件内部缺陷时，超声波换能器产生的机械波波经介质传输至元器件表面并发生反射，产生反射波 x_1 ；入射波则进入塑封器件内部继续传播，当其传播至芯片表面与塑封料分界面时发生反射，产生反射波 x_2 ；当其传输至芯片底部与粘接银浆的分界面时再次发生反射，产生反射波 x_3 。由于入射波强度随入射深度增加而减弱，反射波强度也随之减弱，故要实现不同界面的清晰成像，需要将超声波换能器聚焦于对应界面。图 2.1 为超声波在不同介质层中的传递现象。

超声波扫描显微镜根据界面反射波的相位反转来检测裂纹、空洞、界面分层等缺陷。当分界面处无分层时，入射波从声阻抗低的材料进入声阻抗高的材料，反射系数为正数，反射波为正弦波。反之当分界面处出现分层时，入射波从声阻抗高的材料进入声阻抗低的材料，反射系数为负数，反射波发生相位反转表现为余弦波。超声波扫描显微镜即通过收集各个界面上反射的回波，并通过分析回波的强度及相位信息，得到塑封器件内部结构的一些信息。由于空气的声阻抗接近于零，超声波从任何介质进入空气时，界面上的声强反射率为 0，即超声波不能穿透空气，这是利用超声波检测分层的主要原理。当器件发生封装分层，分层部位可以看作空气层，因此该部位的回波会显示较高的强度，而且这种情况下声压反射系数为 P_R ，相位改变了 π ，正常情况下塑封料与芯片、铜引线框架的波形为上升波，发生分层后波形发生反转，称为下降波。图 2.3 定义了正相、反相反射波的波形和不同的声阻抗比值的关系。所以，依据超声波在塑封器件内部传递所产生的波形，当某个界面的结合产生异常（如分层，气孔等）或本身材质内部异常时均可以被识别出来。




图 2.3 不同介质的反射波形

2.2 超声波扫描显微镜的扫描模式

超声波扫描显微镜的基本扫描模式分为 A、B、C 三种。图 2.4 为回波幅度随时间变化的波形曲线，X 轴为入射波的传输时间，单位为纳秒；Y 轴为反射波的相对幅度。扫描波形图包含了反射波的时间坐标、幅度、相位（正弦波或余弦波）、门限宽度，这些参数是判断缺陷的重要依据。根据 A 扫描波形图中反射波的分布，可初步了解样品内部的界面结构。

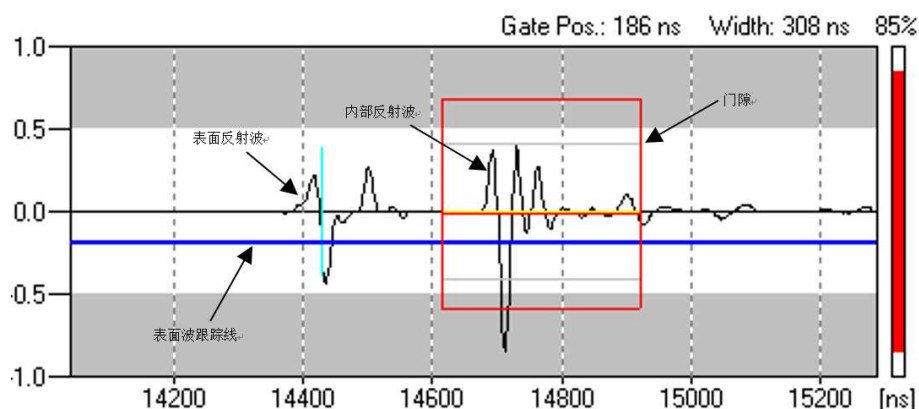


图 2.4 A 扫描波形图

A 扫描模式是超声波扫描成像工作的基础。其工作原理就是将超声波信号垂直入射到被测样品的某一平面坐标点处如图 2.5 所示，实质上就是单点超声回波信号，其携带了单点在竖直方向上被测样品内部的所有信息。A 扫描模式中固定频率的超声波换能器其工作焦距与穿透深度固定不变。以聚焦和引线架为例，移动超声波换能器至聚焦的引线架位置，调节门限位置与宽度使门限至少包含三个穿过横轴的反射波，在固定增益下调节超声波换能器与塑封器件的垂直距离直至 A 扫描波形图中 Y 轴百分比相对幅度达到最大，实现准确聚焦。在 A 扫描模式下，后续可进行其他模式的扫描。图 2.6 即为 A 扫描模式所得塑封元器件的显微图片。




图 2.5 A 扫描模式示意图




图 2.6 元器件 A 扫描图像

B 扫描模式是超声波探头沿 Y 方向运动，并实时采集反射波，实现对样品纵向截面的扫描，将样品纵向截面的图像提取出来，获得截面纵向深度的扫描图像，如图 2.7 所示。图 2.8 中元器件焊板边缘存在界面分层，经 B 扫描可以确认可判断焊板分层在塑封器件纵向截面的深度。




图 2.7 B 扫描模式示意图

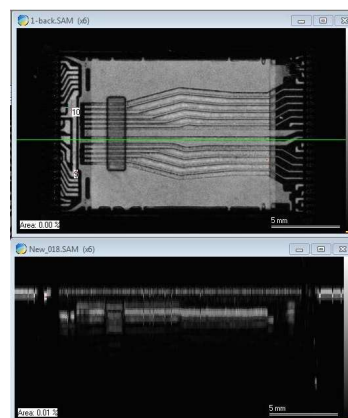


图 2.8 元器件 B 扫描图片

在塑封器件检测中，B 扫描模式的一个重要应用是判断塑封器件中的空洞是否跨越键合丝。空洞若跨越键合丝，参考国军标等对应的判别准则，其属于标准缺陷。根据元器件 B 扫描图片可以获得内部纵向截面结构、样品平整度和缺陷深度等信息，有助于提高缺陷判断的准确性。

C 扫描模式是超声波探头沿 X、Y 平面做二维运动，对整个样品或样品的某一区域进行平面扫描，将感兴趣的某一层上的信息扫描出来，如图 2.9 所示。通过改变 A 扫描模式中波形图门限在 X 轴的位置，C 扫描模式可以聚焦于不同深度的界面，实现样品表面至超声波穿透最大深度范围内的任意水平截面的检测，并对元器件中存在缺陷的位置进行着色标记。图 2.10 为元器件 C 扫描显微图。




图 2.9 C 扫描模式示意图




图 2.10 元器件 C 扫描图片

在塑封器件的失效检测中,为了提高检测效率,可通过建立塑封器件C扫描数据库,保存固化的. SAM 程序文件。当遇到同型号器件时直接调用原程序文件,微调聚焦即可进行 C 扫描。当遇到大量同型号的塑封器件时,将器件依次摆放同一水平面位置,通过在 C 扫描检测区域选择所有的器件,可在高分辨率下一次性扫描成像。由于缺陷的形貌和位置具有一定的随机性,对比同一种器件相同位置的 C 扫描图像灰度,是提高缺陷判断准确率的有效手段。同时, C 扫描图像中器件表面标识的投影也有助于鉴别假冒翻新器件^[66]。

S 扫描为透射扫描。透射扫描需要利用两个垂直对准的超声波换能器,上方超声波换能器作为发射端,下方超声波换能器作为接收端,如图 2.11 所示。由于超声波遇在分层界面发生接近 100%的反射而不会透射,因此接收端接收不到透射波。所以,在 S 扫描图像中分层或空洞缺陷呈现黑色。如图 2.12 所示,图中黑色斑点表示空洞缺陷。




图 2.11 S 扫描模式示意图




图 2.12 元器件 S 扫描图片

S 扫描只能检测塑封器件有无缺陷,而不能准确识别其缺陷位置,其并不适用高可靠领域塑封器件内部缺陷的准确判断。因此, S 扫描一般用于塑封器件生产厂批量化自动检测中。

本实验室超声波扫描显微设备采用德国 PVA 公司的 TePla-SAM 系统, TePla-SAM 系统是目前世界上功能最全的扫描超声波显微镜,如图 2.13 所示,其换能器可以实现从 3MHz 到 2GHz 任意选择,以较好满足不同场合的不同需求。其软件操作界面如图 2.14 所

示。



图 2.13 PVA TePla SAM 系统外观图

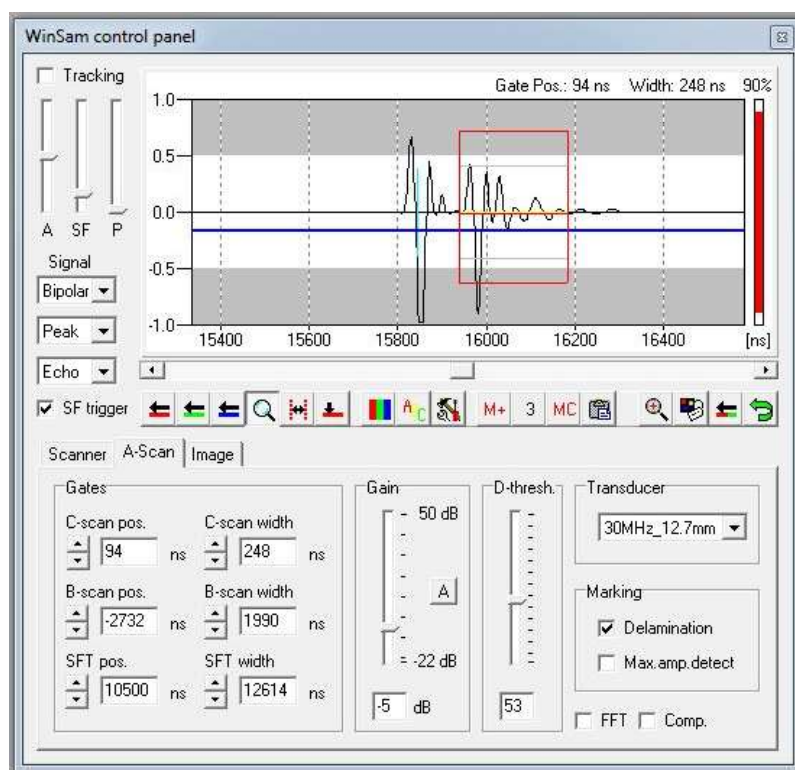


图 2.14 TePla SAM 系统软件界面

2.3 塑封器件封装失效形式

封装是指安装半导体器件芯片用的外壳，其不仅具有密封、固定、保护芯片及加强芯片散热的功能，其还是沟通芯片内部功能与外围电路的桥梁^[67]。封装对于芯片来说是必须的，也是至关重要的，封装的好坏直接影响器件的功能表现。封装失效是半导体器件最常见的失效模式。

导致封装失效的原因有很多，它既可能是封装工艺的失误或者不完善，也可能是封装材料的质量问题。同时，元器件使用不当也将会造成封装失效。常见的封装失效模式主要包括引线键合失效、芯片刮伤或划痕、芯片崩裂或断裂、封装界面分层、空洞、塑封失效等等。

1. 引线键合失效

引线弯曲、键合点脱离、金属断裂、键合点断裂等是引线键合失效的主要表现形式。由于封装设计不当或键合工艺误差引起的机械应力，大电流造成的热过应力，键合系统的化学劣变等因素都将会导致引线键合失效。在采用 Au 丝压焊的 Au-Al 键合系统中，由于 Au 和 Al 的化学性质不同，在长期使用或者储存后，Au、Al 之间将发生一定的化学变化，同时产生五种相关的金、铝化合物： $AlAu$ 、 Al_2Au 、 $AlAu_4$ 、 $AlAu_2$ 、 Al_3Au_5 。而对于采用 Cu 丝压焊的 Cu-Al 键合系统中，Cu、Al 之间也会产生一定的化学变化生成 $CuAl_2$ 、 $CuAl$ 、 Cu_4Al_3 、 Cu_3Al_2 和 Cu_9Al_4 ，由于这些金属化合物的化学性质、晶体结构、膨胀系数各不相同，且导电能力差，因此元器件在经过长期的使用后，器件的键合处将出现变脆、键合强度降低等现象，导致键合系统的界面处产生裂缝，引起器件的性能退化，严重时还将造成器件开路。

2. 芯片断裂

管芯在切割、封装及使用过程中都可能发生断裂，芯片的断裂主要是所受应力不均所引起的。当环氧树脂模塑化合物固化时，将产生热缩应力；或者当塑封半导体器件受到外界温度影响时，也将会产生热缩应力。这些应力会导致有大的拉力和剪切力施加在芯片上^[68]。剪切力，尤其是在芯片角上的剪切力，产生局部拉力且幅度较大，这会使芯片粘合材料、芯片薄膜钝化层或芯片本身产生裂纹，这将会导致器件出现开路、短路和时断时续的问题。此外，产品在装配时焊接产生的热量突变以及产品超功率使用时也会造成芯片出现裂纹或者分层，造成产品失效。

3. 环氧塑封料破裂、空洞和分层

半导体器件的塑封材料主要为环氧树脂和硅酮树脂这两大类。塑封器件在封装过程中由于材料或者工艺的缺陷将导致塑封料与框架、塑封料与芯片之间出现分层或空洞；空洞和分层将会吸收器件外部的水分子，使水分子渗透到器件内部引发失效。此外当温度升高时，空洞和分层在水分子作用下开始膨胀，导致器件内部应力分布不均，产生芯片裂缝、键合点脱落等缺陷。另外，芯片在存储、运输过程中也会吸收周围的水分，当

芯片焊接到电路板上时，局部高温也将会导致塑封器件发生分层失效。

空洞：塑封器件空洞一般是微小的气泡存在于塑封料、芯片粘接层、内部焊点^[69]等位置。在大量的元器件超声波扫描显微镜检测中，本实验室近两年未曾发现因空洞导致塑封器件超声波扫描显微检测不合格的现象。

裂纹：裂纹一般位于塑封料、芯片、芯片粘接层的位置。裂纹的初始形态一般为空洞，在高温环境中空洞将逐渐扩展为裂纹。裂纹将会导致超声波发生散射，在 C 扫描图像中裂纹呈现为黑色条纹。超声波扫描显微镜可以检测出横向裂纹，垂直方向的裂纹无法检测。S. Oberhoff 等人^[70]曾使用红外显微镜（Infrared Microscope IRM）检测 MEMS 传感器引线架与塑封料界面垂直方向的裂纹。根据实验室超声波扫描检测数据，裂纹导致塑封器件不合格的比率的较低。

分层：当环境温度急剧变化时，器件塑料包封（模压化合物）与引线框之间因热膨胀系数的差异会发生分层和开裂。塑封器件内部产生的热缩应力会导致有较大的拉力和剪切力施加于芯片或引线框架上，这些应力将在环氧树脂模塑化合物和芯片、芯片基座、引线框架之间产生分层。同时，在极端低温下，塑封料耐开裂的强度将会下降，这将导致热缩应力加剧，分层和开裂的现象会更加显著。

姜秀杰等人曾对塑封器件基板、芯片的界面分层做出检测，并指出界面分层会影响塑封器件的可靠性、散热以及抗辐射能力。潘凌宇等人曾对功率器件芯片粘接层界面、倒装焊器件基底等界面分层做出检测，并指出其实验室塑封器件超声波扫描显微检测中由于内部界面分层导致的元器件不合格比例占到 99%。综上所述，界面分层是塑封器件内部的主要缺陷，这也是影响塑封器件可靠性的关键因素。本文中将具体介绍各种分层类型的缺陷。

2.3.1 引线架界面分层

引线架界面分层主要是因为应力释放导致引线架变形而造成的。在分层区域中存在一定的空气等，入射波在此发生强反射，在元器件 C 扫描显微图像中，界面分层区域呈现亮白色，而边界处空气受到挤压呈现倾斜斜面，入射波散射严重，反射波强度减弱，因此边缘区域呈现浅灰色。引线架界面发生分层失效是由于引线架在成型过程中受力发生变形或引线架材质与塑封料热膨胀系数不匹配造成的。通过对塑封器件研磨抛光制样，进行超声波扫描显微检测，我们可以确认引线架分层缺陷^[71]。

引线架界面分层是塑封器件最常见的缺陷形式，在近两年的超声波扫描显微检测中，

塑封器件引线架界面分层失效占有所有失效因素的 90%以上。而包含键合丝区域的引线架界面分层则是导致塑封器件发生界面分层的主要因素，其次为引线架后侧从塑封料上完全剥离。

某塑封器件的 C 扫描图像如图 2.15 所示，其中标红区域为引线架与塑封料存在界面分层区域，属于包含键合丝的引线架分层。依据 GJB4027A-2006《军用电子器件破坏性物理分析方法》工作项目 1103 章节 2.4.4 第 h 条^[25]，属于标准缺陷。没有分层区域的 A 扫描波形图如图 2.16 所示，此时反射波未发生相位反转，为正弦波；红色分层区域的 A 扫描波形图如图 2.17，此时反射波发生相位反转，为余弦波。




图 2.15 引线架与界面分层




图 2.16 无分层区域的 A 扫描波形图




图 2.17 分层区域 A 扫描波形图

2.3.2 芯片界面分层

芯片与塑封料的界面发生分层主要是由芯片表面污染导致界面结合力降低而造成的。芯片与塑封料的界面发生分层将不利于芯片散热，芯片在工作时温度升高，从而导致界面分层扩散，这将进一步导致芯片过热，最终使芯片发生失效。在塑封器件超声波扫描显微检测中，芯片界面分层的判据最为严格，任何可以测量的芯片界面分层均属于标准缺陷。然而，根据以往的检测数据，芯片界面出现分层的现象很少，芯片界面分层不是导致塑封器件失效的主要因素。

某塑封器件 C 扫描图像如图 2.18 所示，芯片边角与塑封料界面存在分层，引线架与塑封料界面存在包含键合丝区域的分层。参照 GJB4027A-2006 工作项目 1103 章节 2.4.4 第 e 条、h 条，属于标准缺陷。芯片无分层区域的 A 扫描波形图如图 2.19，反射

波并未发生相位反转，为正弦波；芯片边角红色分层区域的 A 扫描波形图如图 2. 20，反射波发生相位反转，为余弦波。




图 2.18 引线架、芯片与塑封界面分层

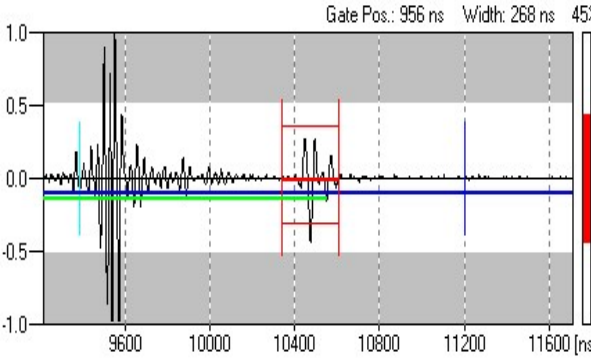


图 2.19 芯片无分层区域 A 扫描波形图

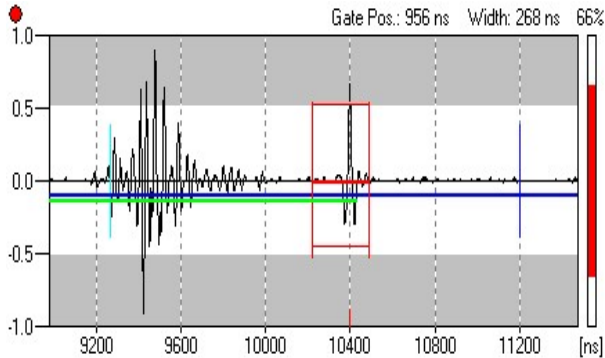


图 2.20 芯片分层区域 A 扫描波形图

在实际检测中，部分塑封器件芯片表面存在涂覆的保护胶，这将导致 A 扫描波形图 为余弦波，存在分层误判的风险。因此，我们应根据分层形貌特点和多个样品 C 扫描图 像综合判断检测结果，区分芯片分层和涂覆胶的情况，防止产生误判。

2.3.3 焊板分层

焊板与塑封料的界面发生分层缺陷主要是由两种材料的界面结合力不均匀引起的。焊板界面分层将不利于塑封器件散热，容易导致器件发生过热失效。据以往超声波扫描 显微镜检数据，塑封器件的焊板界面分层是比较常见的标准缺陷。




图 2.21 焊板与塑封料界面分层

某塑封器件 C 扫描图像如图 2.21 所示，焊板边缘与塑封料界面存在大面积分层。GJB4027A-2006 工作项目 1103 章节 2.4.4 第 f 规定：引线引出端焊板与塑封间界面上，分层面积超过其后侧区域面积的 $1/2^{25}$ ，属于标准缺陷，这对于高可靠领域用塑封器件存在潜在失效风险。

2.4 本章小结

本章主要分析了超声波扫描检测原理和塑封器件检测中常用的 4 种扫描模式。同时分析了塑封器件常见的失效形式，并着重分析了分层失效的几种类型。根据近两年实验室超声波扫描试验所得结果分析发现，在所有的元器件封装失效中，封装分层是最常见的失效形式，而引线架界面分层占有所有分层失效因素的 90%以上。通过超声波扫描显微镜检能有效识别塑封器件分层失效，避免元器件在高可靠领域应用中存在的风险。

3 元器件超声波扫描图片失效特征提取

在上一章中我们主要介绍了超声波扫描检测元器件缺陷的原理、几种常见的扫描模式、元器件塑封失效的形式及其反映在超声波扫描显微图片和波形上的特征。

本章我们将根据上一章节描述的元器件各种失效特征，手工设计失效特征描述子，量化国军标等相关手册中规定的相关失效判别准则，并通过图像处理的方法提取量化的失效特征。本章的相关工作均以塑封元器件的超声波扫描后视图为例进行说明，其后视图的处理方式与之类似，在此不再赘述。本章的相关工作将为下一章利用机器学习的方法识别失效元器件提供数据支撑。

3.1 元器件超声波扫描图像的预处理与分割

在实际的元器件超声波扫描显微检测中，我们一般将多个元器件整齐排列，通过一次扫描得到多个元器件的集体超声波扫描图片，以提高检测的效率，缩短检测时间。由于多个元器件在同一张超声波扫描图片中，在对每个元器件进行失效判别时，我们一般需要先分割出每一个元器件的超声波扫描显微图片，再对其做后续的处理与特征提取工作。

首先利用图像处理技术对多个元器件的超声波扫描图片进行裁剪、滤波、形态学处理，并从中分割出每个单独的元器件。其流程图如图 3.1 所示。

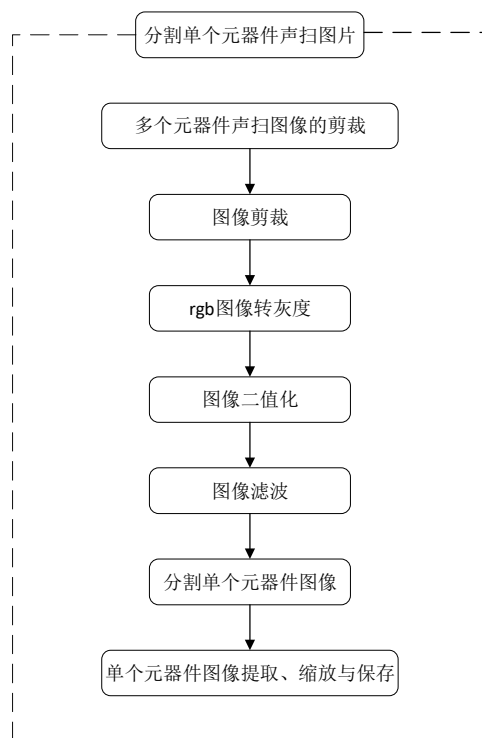


图 3.1 元器件超声波扫描图片分割流程图

Step1. 多个元器件超声波扫描图片的剪裁。

多个元器件的超声波扫描显微图片如错误!未找到引用源。所示。




图 3.2 多个元器件的超声波扫描显微图片

从图 3.2 可以看出原始的元器件超声波扫描图片中存在一部分区域为图像边缘，我们首先对其进行裁剪处理。经过剪裁处理后只保留元器件的主体部分，通过裁剪处理有效的缩小了图片尺寸，减小了后续图像处理的计算量，同时也除去了冗余的信息，避免图像分割错误的发生。

Step2. 图像的灰度、滤波、二值化处理。

将经过裁剪后的多个元器件超声波扫描显微 RGB 图转化为灰度图，同时进行串联滤波处理，以消除图像中存在的孤立噪声点，平滑图像。




图 3.3 多个元器件超声波扫描图片串联滤波处理

对比图 3.2 多个元器件的超声波扫描显微图片和图 3. 多个元器件超声波扫描图片串联滤波处理，我们可以明显看出经过串联滤波处理后的多个元器件超声波扫描显微图片变得更加平滑，图中一些孤立的椒盐噪声点通过串联滤波被滤除。

通过将多个塑封器件的超声波扫描显微图片灰度图转化为二值图，我们能够清楚的看到此时元器件的引线框架与其焊板与模塑化合物分界面分离，因此需对其进行形态学处理。

Step3. 图像的形态学处理。

对二值图进行膨胀处理，使元器件引线架区域与分界面合为一个连通区域，同时滤除图像中孤立的面积较小的区域。通过膨胀处理每一个元器件已将独立为单独的连通区域，我们对元器件的各个连通区域寻找最小的包络区域，对元器件超声波扫描图片进行分割。

Step4. 单个元器件超声波扫描图片的分割。

对上文经形态学处理后的多个元器件超声波扫描显微图片进行分割处理，寻找包络连通区域的最小矩形，但是由于图中的某些噪声区域会干扰准确分割的结果，因此我们需要通过计算矩形框的纵横比，排除不是元器件的部分。分割结果如图 3.3 所示。




图 3.3 各元器件分割图

从图 3.3 中分割出每个元器件的超声波扫描显微图片，此时，每张图片的尺寸大小不一且尺寸均较小因此我们对各个图片进行缩放处理，统一大小和格式。

Step5. 各个元器件超声波扫描显微图片的提取、放缩与保存。

从经过分割处理后的元器件超声波扫描显微图片中提取出单个元器件的超声波扫描图片，并对超声波扫描显微图片进行放大处理，统一尺寸，为后文失效特征的提取提供条件和基础。

在实际的超声波扫描显微镜检中，技术人员一般一次扫描多个元器件，通过对元器件超声波扫描显微图片的分割处理，可以在一次扫描中获得每个元器件的超声波扫描图片，接下来在对单张元器件图片进行自主失效判别，这种方法减少了技术人员的操作负

担。

3.2 潜在失效元器件超声波扫描显微图片的筛选

通过上述步骤的处理我们已经可以得到每个元器件的超声波扫描显微图片，然而在实际检测中发现在一次扫描得到的多张元器件超声波扫描显微图片中大量元器件并未发生失效，因此我们需要对得到的每个元器件超声波扫描显微图片进行筛选处理，排除一些明显可靠的元器件图片，只保留发生失效概率较大的元器件图片。

Step1. 初筛元器件超声波扫描显微图片。

参考有关国军标等规范手册及超声波扫描系统相关技术文档，若超声波扫描图片中没有标红区域，则可以认为该元器件并不存在塑封缺陷，或存在缺陷的可能性极小。因此，首先排除不存在红色区域的超声波扫描显微图片。

此外经过初次筛选后的超声波扫描显微图片中一部分图片其红色区域并不位于元器件的引线架或引线引出端焊板与模塑化合物分界面处，该红色区域面积很小为孤立的噪声点。因此我们需要再次筛选排除这一部分超声波扫描显微图片。

Step2. 复筛元器件超声波扫描显微图片。




图 3.4 复筛后的元器件超声波扫描显微图片

经过二次筛选处理，得到发生潜在失效概率较大的元器件超声波扫描显微图片，并将其作为失效特征提取的处理样本，如图 3.4 所示。因此在实际应用中只需对上述样本进行失效判别，提高了工作效率。

3.3 失效特征描述子的设计与提取

参考国军标相关元器件超声波扫描失效判据：GJB4027A-2006 项目 1103 章节 2.4.4f 条，标红区域位于元器引线引出端焊板与模塑化合物的分界面处，该区域分层面积超过

其后侧区域面积的 50%属于标准缺陷，需要拒收^[25]。GJB4027A-2006 项目 1103 章节 2.4.4g 条，引脚从塑封完全剥离（上侧或后侧）属于标准缺陷，需要拒收^[25]。设计失效特征描述子分别为标红区域所占面积比率与标红区域形心位置坐标。同时对失效情况进行分类讨论：

1. 标红区域只位于引线架处，此时计算各个标红区域面积占引线架面积的比率，并取最大值作为最后结果。
2. 标红区域只位于元器件引线引出端焊板与模塑化合物分界面处，此时计算各标红区域与分界面的面积比率，并对计算结果求和。
3. 标红区域同时位于引线架与引线引出端焊板与模塑化合物分界面处，此时分别对情形 1、2 中进行计算。

通过对三种失效情形分别进行处理，提取出每种失效情形的失效特征，流程图如下所示。

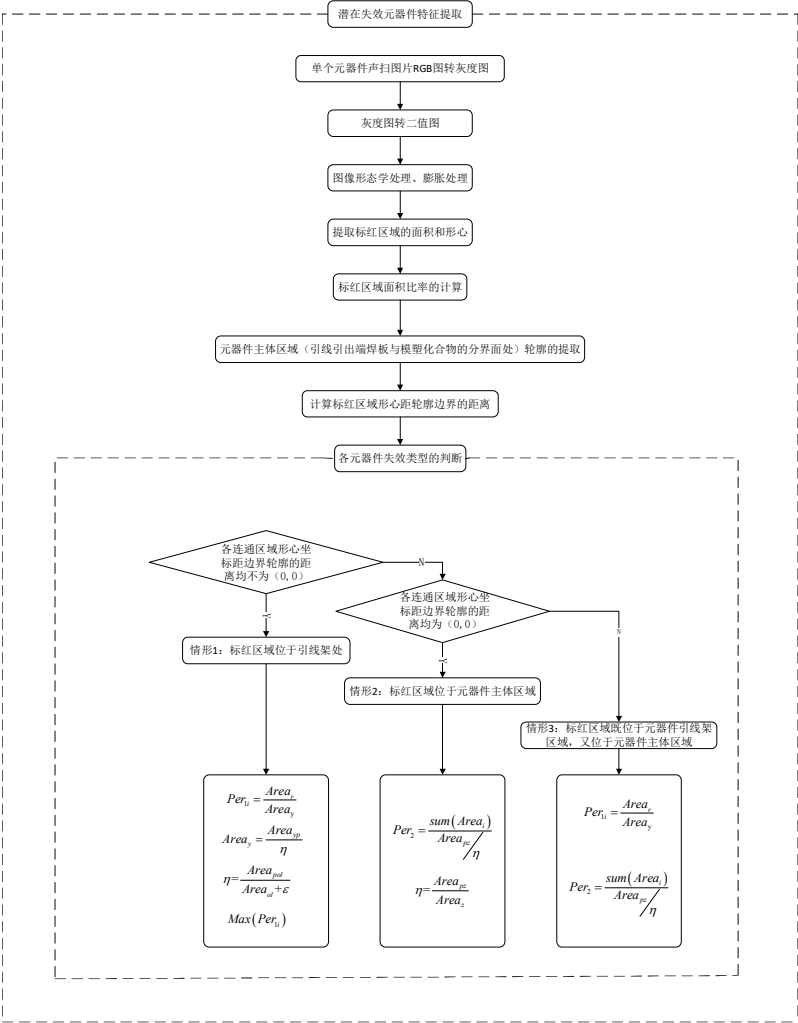


图 3.5 失效特征提取流程图

如图 3.5 所示，首先对筛选出的元器件超声波扫描显微图片进行预处理，获得图片标红区域的形心坐标、面积比率和元器件轮廓曲线，然后根据形心坐标距轮廓曲线距离判别其失效类型。具体过程如下。

3.3.1 塑封器件超声波扫描图片预处理

失效类型 1：标红区域位于引线架处。

I. 塑封器件超声波扫描图片 RGB 图转灰度图、二值图。

为计算标红区域所占单个引线架区域的面积比率，首先对元器件超声波扫描显微图片进行处理。



图 3.6 超声波扫描 RGB 图 图 3.7 超声波扫描灰度图 图 3.8 超声波扫描二值图

从图 3.6 二值图中可以明显看出标红区域的引线架存在明显的分层，此时若要计算单个引脚的面积比较困难，我们需要将各个分离区域连接为一个整体。因此，首先对灰度图进行形态学处理，然后在进行膨胀处理，使引线架形成一个完整的连通区域。

II. 塑封器件超声波扫描灰度图形态学处理、膨胀处理。

对元器件超声波扫描灰度图进行形态学处理，同时对二值图进行膨胀处理，并提取出其标红区域，结果如下所示。



图 3.9 灰度图形态学处理 图 3.10 二值图膨胀处理 图 3.11 标红区域的提取

观察图 3.9 经过膨胀处理的元器件超声波扫描显微二值图，引线架的分层区域已经连通为一个整体，此时可以方便计算每个引脚的面积大小。同时提取出扫描图片中的标

红区域如图 3.9 所示。

经过膨胀处理后的元器件引线架区域面积与原始图片中的引线架相比，其面积更大，因此在面积比率的计算时需要进行修正处理。此时我们可以对提取出的标红区域进行同样的膨胀处理，与引线架保持相同的放大比例。同时也可以对膨胀后的引线架面积进行还原。为保证与原始数值信息保持一致，本文选择第二种方法，将膨胀后的引线架面积进行还原处理。计算公式如式（3.1）所示。

$$\eta = \frac{Area_{pol}}{Area_{ol} + \varepsilon} \quad (3.1)$$

上式中， η 为修正系数；

$Area_{ol}$ 为膨胀处理前所有引线架的面积之和；

$Area_{pol}$ 为膨胀处理后所有引线架的面积之和；

ε 为松弛变量，不同情况下该值的大小一般不同，经大量实验验证 ε 取值范围在 $[0, 0.4]$ 时较为合理。

失效类型 2：标红区域位于元器件引线引出端焊板与模塑化合物的分界面处。

与失效类型 1 处理方法相同，首先将元器件原始超声波扫描显微 RGB 图（图 3.12）转灰度图（图 3.13）、二值图（图 3.14），对二值图进行膨胀处理，灰度图进行形态学处理（图 3.15），同时提取出标红区域（图 3.17）。



图 3.12 超声波扫描 RGB 图 图 3.13 超声波扫描灰度图 图 3.14 超声波扫描二值图




图 3.15 灰度图形态学处理 图 3.16 二值图膨胀处理 图 3.17 标红区域的提取

标红区域面积修正系数计算公式如下。

$$\eta=\frac{Area_{pz}}{Area_z} \tag{3.2}$$

上式中， $Area_{pz}$ 为经膨胀处理后元器件主体部分面积；

$Area_z$ 为膨胀处理前元器件主体部分面积。

3.3.2 元器件失效情形的确定及标红区域面积比率的计算

上文对元器件超声波扫描图片进行预处理，提取出标红区域，接下来需要根据特征失效描述子计算出对应的数值。首先对元器件超声波扫描二值图进行处理，滤除图片中的引线架区域，只保留元器件引线引出端焊板与模塑化合物分界面区域，并获得该区域的轮廓曲线，图 3.12。根据标红区域的形心坐标距轮廓曲线的举例确定元器件失效类型。

I . 元器件边缘轮廓的提取。



图 3.18 元器件分界面区域




图 3.19 元器件边缘轮廓

在塑封器件扫描显微图片的左上顶点建立直角笛卡尔坐标系如错误!未找到引用源。所示，根据图片坐标系，我们能够精确的确定出元器件扫描图片的上、下、左、右边界位置。

II . 计算各标红区域形心坐标与元器件轮廓的距离。




图 3.20 形心距边界距离示意图

将元器件超声波扫描图片分为 9 个区域，其中元器件引线引出端焊板与模塑化合物分界面区域即图 3.18 对应区域为区域 5。元器件引线架位于其他 8 个区域内。假设 x, y 分别表示元器件标红区域形心距左右、上下边界的距离，若形心坐标位于区域 5 内则定义 x, y 均为 0。对于失效情形 1，计算图 3.6 中各个标红区域的形心坐标距离元器件边界轮廓的距离分别为 (9, 11.89), (0, 12.45), (0, 14.06), (6.10, 22.42)。而对于失效情形 2，根据假定，图 3.12 中各个标红区域的形心距元器件边界的距离分别为 (0, 0), (0, 0)。

III. 元器件超声波扫描图片失效类型的判断。

参考相关技术标准，若各个标红区域的形心坐标与元器件边界轮廓的距离均不为 (0, 0)，则为失效类型 1。若各个标红区域的形心坐标与元器件边界轮廓的距离均为 (0, 0)，则为失效类型 2。否则为失效类型 3

3.3.3 标红区域面积比率的计算

通过 3.3.1 中对元器件超声波扫描图片的预处理，获得元器件的各个标红区域，对每个标红区域计算面积比率。

失效类型 1：标红区域位于引线架处。

记各个引线架连通区域的形心坐标为 (x_i, y_i) ，各个标红区域的形心坐标为 (x_j, y_j) 。

计算 $\min(|x_i - x_j| + |y_i - y_j|), (i = 1, 2, \dots, m; j = 1, 2, \dots, n)$ 。寻找距各个标红区域形心点最近的引线架形心，该引线架即为标红区域所对应的引线架。计算标红区域的面积比率。

$$Per_1 = \text{Max}(Per_{1i}) = \text{Max}\left(\frac{Area_{ri}}{Area_{yi}}\right)$$

$$Area_{yi} = \frac{Area_{ypi}}{\eta} \quad (3.3)$$

$$\eta = \frac{Area_{pol}}{Area_{ol} + \varepsilon}$$

上式中， η 为修正因子；

Per_{1i} 为每标红区域 i 占其所处引线架面积的比率；

$Area_r$ 为单个标红区域的面积；

$Area_y$ 为膨胀处理前单个标红区域所处的引线架面积；

$Area_{yp}$ 为膨胀处理后标红区域所处的引线架面积；

$Area_{ol}$ 为膨胀处理前所有引线架的面积之和；

$Area_{pol}$ 为膨胀处理后所有引线架的面积之和；

ε 为松弛变量，这里取 0.3。

取各个标红区域与其对应的引线架区域面积比率的最大值 $Per_1 = \text{Max}(Per_{1i})$ 作为最终所得结果。计算图 3.6 中各个红色区域的面积比率，分别为：0.0470, 0.4492, 0.7627, 0.2487；其中 $\text{Max}(Per_{1i}) = 0.7627$ 。

失效类型 2：标红区域位于元器件引线引出端焊板与模塑化合物的分界面处。

将各个标红区域面积求和，计算标红总面积与元器件引线引出端与模塑化合物分界面面积的比值。计算公式如下。

$$Per_2 = \frac{\text{sum}(Area_i)}{Area_{pz} / \eta} \quad (3.4)$$
$$\eta = \frac{Area_{pz}}{Area_z}$$

上式中， Per_2 为标红区域面积占元器件部分的比率；

η 为修正因子；

$Area_i$ 为元器件主体部分内每个标红区域的面积；

$Area_{pz}$ 为经膨胀处理后元器件主体部分面积；

$Area_z$ 为膨胀处理前元器件主体部分面积。

对于图 3.12，计算标红区域占元器件引线引出端焊板与模塑化合物的分界面面积的比率为 0.0096。

失效类型 3：标红区域既存在于引线架区域又存在于元器件引线引出端焊板与模塑化合物的分界面内。

分别计算失效类型 1 和失效类型 2 中的标红区域面积比率，作为失效类型 3 的输出。

综上所述，分别对元器件的三种失效形式的特征描述子即标红区域面积比率进行了讨论，在下一章中将重点研究将设计的失效特征描述子计算结果作为机器学习输入，训

练模型实现元器件失效自主识别。

3.4 本章小结

本章主要包括：

1. 对多个元器件的超声波扫描显微图片进行分割处理，得到统一尺寸的每一元器件超声波扫描显微图片并保存。
2. 对元器件超声波扫描图片进行筛选，得到发生失效概率较大的失效元器件超声波扫描图片。
3. 参考国军标的相关判别失效准则，设计失效特征描述子，对元器件的三种失效类型分别进行讨论。对筛选出的元器件超声波扫描显微图片进行预处理，计算出标红区域形心坐标距元器件边界的距离，判别其失效类型。根据不同的失效类型分别计算出标红区域的面积比率，作为模型的输入。

4 塑封元器件失效识别模型研究

根据章节 2, 3 的相关工作介绍, 本文对塑封器件超声波扫描显微图片进行分割、图像处理, 提取出失效特征。章节 3 中对元器件的 3 种塑封失效类型分别进行了讨论, 并针对不同的类型设计、提取量化特征。然而, 实际上经过大量的超声波扫描检测发现, 元器件的塑封失效类型绝大部分为情形 1, 即引线架出现分层。失效类型 2 引线引出端焊板与模塑化合物的分界面分层的失效情况很少, 失效类型 3 目前并未发现。因此本论文将只对失效类型 1 做具体讨论, 对于失效类型 2 和 3, 可以采用类似的方法进行分析。元器件超声波扫描图片失效识别流程图如图 4.1 所示。

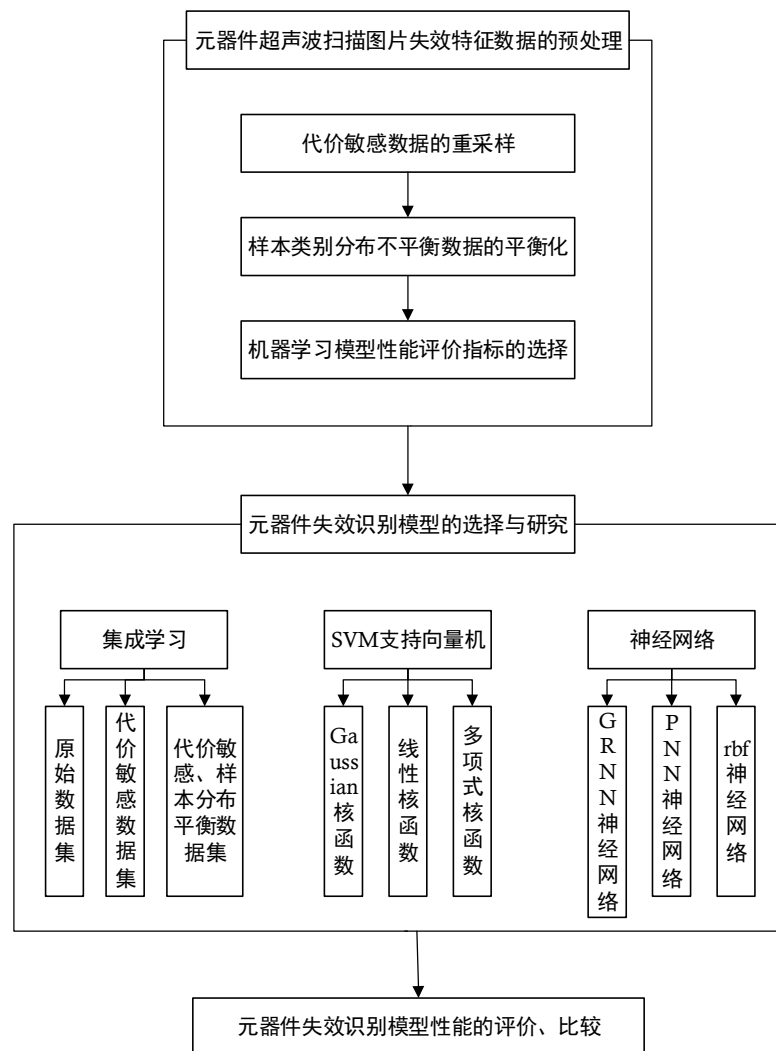


图 4.1 元器件超声波扫描图片的失效识别流程图

具体来说, 首先对检测积累的大量塑封器件超声波扫描图片进行人工失效判别并做上标记。然后对做好标记的扫描图片进行分割和特征提取。接下来对元器件失效特征数

据进行分析，利用重采样的方法使样本类别分布平衡化并使数据具有代价敏感性，同时将经过预处理后的样本数据分为训练集和测试集，并利用训练集训练多种不同类型的模型、网络。最后根据调优的模型对测试集中元器件失效特征数据进行判别，并分析比较各模型的综合性能。

4.1 塑封元器件失效特征数据分析

在实际的分类中经常会遇到这样的问题，如在医疗诊断中，某种传染病（如 H1N1）流行期间，小李由于身体不适看病就医，此时医生可能会给出两种诊断结果：1. 普通感冒；2. 致命流感 H1N1。此时的分类目标是将致命流感从普通感冒中检测出来，实际检测中出现的分类错误包括以下两种：1. 将普通感冒误诊为 H1N1；2. 将 H1N1 误诊为普通感冒。显然错误 2 所带来的后果将比错误 1 要严重的多。此时患者不仅会错过最佳治疗时间出现生命危险，而且流感传播后带来的损失将无法估量。也正是由于这一点医院往往采取“宁可错杀一千，不可放过一个”的保守措施，这是对病人的负责，更是对社会负责。从这个例子中可以清楚发现，两种错误所带来的代价将有天壤之别。对于这类问题如果采用普通的机器学习方法将会存在较大的风险。上述例子说明数据存在较为严重的代价敏感性。

除代价敏感以外，在实际应用中也还会出现这样的情况，有些类别的样本数目会比其它类别的少，这种数据特征称为类别不平衡性。在某些情况下数据的不平衡比例将高达 100 倍、1000 倍、10000 倍^{[72], [73], [74]}甚至更高^[75]。类别不平衡性普遍存在于各个领域，如金融诈骗检测、石油勘探、网络入侵检测、反垃圾邮件、文本分类、生物信息、医疗检测等等^[76]。当类别存在不平衡现象时，标准的分类方法一般会将小类样本误分到大类中，以得到较低的错误率。如一共有 1000 个样本，而实际正例只有 1 个，此时不平衡比例高达 1000 倍，若将样本全判断为正例，此时错误率仅为 0.1%，但是这种低错误率对分类器的效果评价并没有任何意义，该分类器完全无用。所以，当样本数据存在不平衡性时，通常也隐含了在实际应用中更加关注小类别这一假设。此时，错误率对分类器性能的评价以不再适用。PR 曲线（precision-recall curve）、ROC 图、F 值、G-mean（几何平均）等，由于其关注正类，而不受分布的影响，因此在样本非平衡分布时更能反映分类器的真实性能。因此对于类别不平衡问题，其实际上包含两个要素：（1）类别样本分布具有不平衡性；（2）小类样本是关注点。

由于类别不平衡问题本质上需更关注小类样本，因此样本类别分布不平衡往往和敏

感学习紧密联系。它们都涉及到真实问题中对分类器效用的要求不同于标准机器学习技术，都偏好某个类别(敏感学习偏好代价高的样本类别，类别不平衡偏好小样本类别)，因此可以采用相似的方法来处理它们。

本论文研究对象的应用场景为塑封器件在高可靠性领域中的应用，因此在实际判别失效时一般在尽可能的保证塑封器件的失效均被正确识别的基础下允许部分元器件被误判为失效，即认为错误类型 2 的风险代价要高于错误类型 1, 该分类问题属于代价敏感学习。此外在实际检测中塑封器件大部分为未失效器件，出现失效的情况较少，约为未失效样本的 1/10, 因此样本还存在一定的不平衡性。所以本文的研究对象为代价敏感分布不平衡样本。

4.1.1 失效特征数据的代价敏感学习

当分类错误具有代价敏感特性时，能使总体代价达到最小的分类器即为最优分类器，因此在一般情况下学习目标应使总体代价最小化。对于二分类问题，代价矩阵是一种直观表示错分代价的方法。代价矩阵将预测类别与实际类别每种可能组合的错分代价以矩阵的形式表现出来，形成代价矩阵。错分代价混沌矩阵如**错误!未找到引用源。**所示。

表 4.1 代价矩阵

	实际正类	实际负类
预测正类	0	Cost (A)
预测负类	Cost (B)	0

错误!未找到引用源。中正确分类代价为 0，第一类错误(实际负类预测正类)的代价为 Cost(A)，第二类错误(实际正类预测负类)的代价为 Cost(B)。在有监督学习的分类问题中，对于基于类别的代价，假设 $S = (x_i, y_i)_{i=1}^n$ 为训练集，其中 x 表示 d 维输入空间 X 的样本， $y_i \in Y$ 表示样本的类别， $y_i \in \{s_1, s_2, \dots, s_m\}$ 。并假设样本服从 $X \times Y$ 空间中的分布 D 。 $\text{cost}(i, j)$ (简记为 $\text{cost}_{i,j}$) 表示将 s_i 类的样本误分到 s_j 类的代价。此时学习目标是学习一个分类器 $h: X \rightarrow Y$ 对未知样本进行分类，使得分类后期望代价最小，即最小化式 (4.1)。

$$\arg \min_h E_{(x,y) \sim D} [\text{cost}_{y, h(x)}] \quad (4.1)$$

实际情况中一般样本分布 D 未知，在学习过程中只能通过最小化经验风险得到 h ：

$$\arg \min_h \sum_{i=1}^n \text{cost}_{y_i, h(x_i)} \quad (4.2)$$

对于基于样本的代价，假设 $\text{cost}(x, i, j)$ 为将 s_i 类样本 x 误分到 s_j 类的代价，则样本 (x, y) 的误分类代价将会是一个 R^m 的空间 Z 中的向量 $\vec{C}_{x,y}$ ， $\vec{C}_{x,y} = [\text{cost}(x, y, 1) \dots \text{cost}(x, y, m)]$ 。将误分类代价看为一个随机变量，于是假设由 (x, y) 及其代价 $\vec{C}_{x,y}$ 构成的样本服从 $X \times Y \times Z$ 空间的分布 D 。其学习目标为学得一个分类器 $h: X \rightarrow Y$ 对未知样本进行分类，使得期望代价最小。

$$\arg \min_h E_{(x,y,\vec{C}_{x,y}) \sim D} [\text{cost}(x, y, h(x))] \quad (4.3)$$

目前国内外常见的代价敏感学习方法主要有三类：

(1) 直接构造代价敏感的分类模型，进行代价敏感学习。该方法与传统的非代价敏感分类算法相比，其直接将误分类代价引入算法，进行代价敏感学习。该思想最具代表性的研究包括 Tumey 提出的 ICET 算法，ICET 算法通过在遗传算法适应函数中引入误分类代价进而演化出决策树归纳算法偏向种群，从而生成代价敏感的决策树^[77]；凌晓峰等人在树的构建过程中考虑误分类代价，提出了最小代价决策树算法，该算法与基于信息熵的属性选择 C4.5 算法不同，其在选取属性时要考虑误分类代价，选择当前期望代价最小的属性作为划分的参考属性^[78]。

(2) 按照传统的学习方法构建分类模型，然后根据贝叶斯风险理论对其结果进行调整，以达到损失代价最小化。该思想中具有代表性的算法包括 Pedro Domingos 提出的 MetaCost^[79]。MetaCost 算法的核心思想是先根据最优条件风险公式改变训练样本的类标签，然后使用改变标签后的样本数据训练集训练分类器。该算法首先利用 Bootstrap 技术采取有放回的采样方式从训练集中生成 n 个子训练集，然后在这 n 个子训练集中学习获得 n 个分类器，再利用 Bagging 算法投票产生类成员概率，并利用最优条件风险公式计算出样本的新类别标签，最后在改变标签的训练集上训练生成代价敏感的分类器。此外，蔡晓永等人提出了代价敏感朴素贝叶斯学习算法，该方法利用朴素贝叶斯可以输出类别成员的特点，采用代价敏感矩阵实现分类的代价敏感性^[80]。

(3) 基于传统学习模型，通过改变原始训练样本数据的分布来训练得到代价敏感的分类模型。该方法的主要思想是通过改变训练样本中不同类别样本所占比例，使样本类别分布与类别代价分布相同，然后利用新的训练样本集来训练分类模型，从而得到代价敏感的分类器。该思想的主要代表算法包括 Zadrozny 等人提出的代价比例采样法^[81]。

该方法通过有放回的比例采样，在训练集中复制样本，根据采样所得样本训练分类器，使分类器实现代价敏感化。然而，复制的样本将会使分类模型在训练过程中容易出现过拟合的现象。Ting 提出的权值法^[82]也是该思想应用于代价敏感学习的典型代表。权值法是重采样方法的一种，该方法通过赋予不同类别样本不同的权值来改变类别样本分布，使其渐进的拟合代价分布。Ting 将上述思想运用至 C4.5 算法中，实现了代价敏感决策树的生成。代价比例采样法是通过使分类器过拟合来实现分类器的代价敏感化。

4.1.2 失效特征数据的类别不平衡性

传统的分类任务主要是在平衡化的数据集下进行的，例如在一般的文本分类问题中，通常把文本看作为要分类的数据，此时文本所属的类别数量分布较为均衡，同时抽样选取的训练文本其类别分布也较为平衡。一般意义上的分类算法均是基于这个前提假设来对样本进行学习和分类的，但是一旦数据出现分布不平衡的现象，一般的分类算法如果还是不加任何调整而进行训练，其效果往往不尽如人意。因此为解决不平衡数据的分类问题，通常从数据平衡化和代价敏感方法的角度去对原有的分类算法进行改进。

1. 数据平衡化方法

解决不平衡数据分类简单有效的方法就是采取措施让数据在预处理阶段就将不平衡特征的数据平衡化，一般情况重采样技术是比较常见的方法，其主要分为欠采样和过采样两种。

a. 样本的欠采样

欠采样技术是通过从数据集中的负类样本进行采样，来达到平衡样本数据分类类别的目的。其中随机欠采样是采样技术中最简单的一种，该方法通过随机地删除数据集中的负类样本，以此来减轻数据集的不平衡程度，当数据集中存在噪音时，采用随机欠采样方法一般能达到不错的效果。虽然此方法容易操作，但是其存在丢失负类样本中有价值信息的风险。

Tomek 在 1976 年率先提出了 Tomeklinks 方法^[83]，该算法的大致思想为： x_i 和 x_j 是从属于不同类别的样本， $d(x_i, x_j)$ 表示两者之间的距离，如果不存在这样一个样本 x_k 使得 $d(x_i, x_k) < d(x_i, x_j)$ 和 $d(x_j, x_k) < d(x_j, x_i)$ 均成立，就认为 (x_i, x_j) 形成了一个 Tomeklinks 对，样本 x_i 和 x_j 中的一个可能为噪音，或者认为它们均在边界上。在样本类别分布不平衡的集合中，可以通过此方法将所有符合 Tomeklinks 的样本对查找出来，

然后将这些点对中的负类样本剔除，以达到对负类样本欠采样的目的。

近邻清除法是一种利用 KNN 聚类算法思想^[84]删除负类样本的欠采样方法。该算法的基本思路为：针对样本集合中的每一个样本，寻找与其最相邻的三个样本，判断当前样本与这三个样本的多数类别是否一致。假如当前样本为正类，而三个最近邻样本中至少两个是负类样本，则删除这三个近邻中的负类样本。假如当前样本为负类，而三个最近邻的样本中至少两个为正类，则删除该样本。从上述过程中可以看出，近邻清除法能够有效的达到欠采样的效果。

b. 样本的过采样

随机过采样是最简单的过采样方法，它是通过随机复制正类样本来增加正类数量。该方法存在的最大缺点为容易造成分类算法的过拟合。另外一方面，由于数据量的增加，同时也会导致训练时间的延长。

SMOTE 算法^[85]是过采样中经常使用的方法，同时该算法的效果在大多情况下也较为理想。SMOTE 的基本思想为：在距离较小的正类样本之间通过对这两个正类样本进行随机的线性插值来产生一个新的正类样本。SMOTE 算法会在样本集合中增加一些计算机模拟生成的正类样本，从而使得不平衡样本平衡化。该算法具体流程为：针对每一个正类样本 x_i ，找出 m 个样本最近的 k 个近邻样本，从近邻样本中选择 m 个样本，然后对这 m 个中的每一个样本 $x_j (j=1,2,...,m)$ ，按照式 (4.4) 生成新的样本点，并且将这些样本划分到正类中，同时参与模型的训练。

$$x_{new} = x_i + rand(0,1) \times (x_j - x_i) \quad (4.4)$$

其中， $rand(0,1)$ 产生 0 到 1 的随机数，在不同的应用场景中可以根据实际需求来控制产生样本的数目。实验结果表明，SMOTE 算法可以较好地避免分类算法中过拟合问题，其能够较大地提升正类样本的分类准确率。此外，训练算法的整体分类精度也不会因为前期的 SMOTE 的采样而降低。

c. 代价敏感方法

代价敏感学习最初是根据不同类别采用不同的误分惩罚，对于那些认为比较重要的类别样本赋予较高的错分代价，而使得分类器在学习过程当中更倾向于关注高代价类别样例。将该思想应用于类别分布不平衡的数据中，将正类样本视为重要程度较高的样本，因此在算法设计中考虑对错分的正类样本赋予更高的权值，使得分类算法在训练过程中

跟倾向于对正类样本的学习，以此抵消负类样本数目较多的影响。已有实验表明，该方法对于解决样本数据分布不平衡分类问题有较为明显的效果。然而代价敏感学习必须事先确定错误分类的代价值，而这一前提条件在实际操作中很难满足。另外一方面，代价敏感学习比较容易出现过拟合现象。

4.1.3 代价敏感分类器综合性能的评价

由于样本数据存在一定的分布不平衡且代价敏感，因此在评价分类器综合性能时，精确率已不再适用。对于二分类问题，一般可将样本根据其真实类别与机器判别类别结果组合为真正例 TP、假正例 FP、真反例 TN、假反例 FN 四种情形。因此有 $TP+FP+TN+FN=$ 样例总数。其组合结果如[错误!未找到引用源。](#)所示。

表 4.2 分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP	FN
反例	FP	TN

标准的分类器一般将对样本计算一个实际或概率预测，然后确定一个分类阈值，将预测值与分类阈值进行比较，若大于阈值则认为该样本属于正类，否则该样本属于反类。在不同的应用任务中，一般根据需求的不同对阈值进行调整，例如如果该应用更重视“查准率”，即希望预测为真正例 TP 的数目占有所有预测正例（ $TP+FP$ ）数目的比值大，则可将阈值设置较大（假设阈值越大预测为正例的数目越少）。若应用更重视“查全率”或“召回率”，即希望预测为真正例 TP 的数目占有所有实际正例（ $TP+FN$ ）数目的比值大，则可将阈值设置较小。一般情形下根据预测结果对样例进行排序，以此来确定阈值大小。因此，排序本身质量的好坏，直接反映了综合考虑分类器在不同情况下的“期望泛化性能的好坏”。对此，可以通过 ROC 曲线来评价分类器的泛化性能。

定义真正率 TPR、假正例率 FPR 分别如下所示。

$$TPR = \frac{TP}{TP + FN} \quad (4.5)$$

$$FPR = \frac{FP}{TN + FP} \quad (4.6)$$

以假正例率为横轴，真正例率为纵轴绘制 ROC 曲线。具体来说，根据分类器的分类结果对预测样例进行排序，然后将分类阈值设置为最大值，即把所有样例均预测为反例，计算标记点坐标 TPR、FPR。接下来将分类阈值依次设为每个样例的预测值，计算标记点

的坐标，最后将相邻标记点用线段连接起来得到 ROC 曲线。

如果一个分类器的 ROC 曲线完全“包含”另一个分类器的 ROC 曲线，则可认为前者的性能优于后者，若两个分类器的 ROC 曲线有交叠，则无法准确断定分类器性能“孰强孰弱”，此时可以根据 ROC 曲线包围的面积 AUC 来进行比较。记每个标记点的坐标为 $\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ，根据 ROC 曲线的绘制过程可以估算 AUC 如式所示：

$$AUC = \frac{1}{2} \sum_{i=1}^{m-1} (x_{i+1} - x_i) \cdot (y_i + y_{i+1}) \quad (4.7)$$

此外由查准率与查全率绘制的 P-R 曲线也能在一定程度上反映分类器在总体样本上的综合性能。

4.2 元器件样本特征数据的预处理

对塑封器件超声波扫描检测样本数据分析，塑封器件的失效样本数据具有敏感性和非平衡分布的特征。对此本论文首先针对数据的非平衡型对数据进行平衡处理，然后对数据进行代价敏感学习。

4.2.1 代价敏感样本的预处理与数据的分布平衡化

在二分类问题中，假设正类和反类的样本数分别为 n_+, n_- ，误分类代价分别为 c_+, c_- ，记正确分类代价为 0，并假设正类为高代价类，因此有 $c_+ > c_-$ ，同时假设 $c_- = 1$ ，则有 $c_+ > 1$ 。

本论文利用代价敏感学习中重采样的方法使学习器具有代价敏感性。重采样的方法采用通用型敏感学习的方法，在重采样的方法中，各类别在学习过程中的影响与他们各自的误分类代价成正比，定义正类相对于反类的最优调整比如式（4.8）所示：

$$rc_{+,-} = \frac{c_+}{c_-} \quad (4.8)$$

此时仅考虑了代价敏感性，因此称 $rc_{+,-}$ 为代价调整比。

同时查阅资料知，代价敏感学习也是一类有效的类别不平衡的学习方法^{[86], [87]}，它对小类样本赋予更大的误分类代价，以此来反映小样本类别的重要性。若使用重采样的方法解决类别不平衡的问题，为使数据集完全平衡，需要使正类相对于反类的最优调整比为：

$$ri_{+,-} = \frac{n_-}{n_+} \quad (4.9)$$

即，小类更为重要。此时仅考虑了类别不平衡性，因此称 $ri_{+,-}$ 为类别平衡调整比。通过类别不平衡调整比即可获得样本平衡分布。

研究表明可以用相似的方法来解决样本的分类敏感问题和代价不平衡问题^[88]。重采样可通过阈值移动、采样和样本加权等方法实现，而这些方法都可以通过对不同的类别设定不同的偏置从而加强重要类别在学习过程中的影响力，因此其既可以用来解决代价敏感问题，同时又可以用来解决类别不平衡问题。为了使重采样技术在解决代价敏感问题的同时解决样本类别分布不平衡的问题，需要结合代价调整比和样本不平衡调整比，一种简单的结合方式是直接将两个调整比相乘得到最终的样本调整比，如式（4.10）所示。

$$r_{+,-} = \frac{c_+}{c_-} \times \frac{n_-}{n_+} \quad (4.10)$$

$r_{+,-}$ 可以理解为将类别分平衡化后，再考虑样本的代价敏感性所得到的调整比。称 $r_{+,-}$ 为综合调整比。

当正类样本为高代价样本且样本数目要小于负样本数目时，相对于原始类别分布下的代价调整比，消除样本的类别不平衡性后的综合调整比将变大，即 $r_{+,-} > rc_{+,-}$ 。从代价敏感学习的角度来看，由于样本量的稀少，正类的误分类代价将比原问题给定的代价值更大。这将意味着，使用数据类别平衡的分布等价于对各类样本的误分类代价基于类别中的样本数目进行规范化处理。

$$c'_+ = \frac{c_+}{n_+}, c'_- = \frac{c_-}{n_-} \quad (4.11)$$

由于在重采样的方法中，改变样本类别分布和改变代价比是等价的，因此该方法非常适合用以研究类别不平衡性对代价敏感学习的影响。

4.2.2 元器件失效特征数据的重采样

利用重采样的方法，对元器件样本数据进行预处理。在元器件的扫描显微检测中，首先技术人员参考国军标等技术手册中对塑封器件扫描图片缺陷判别的判据并结合自身经验，对大量的塑封器件扫描检测图片进行失效判别，并做好标签。通过图像的分割和处理，一共获得了 6454 张塑封器件的超声波扫描图片所对应的失效特征，如表 4.3 所示。

表 4.3 塑封器件失效特征原始数据（截取部分）

面积比率	失效标签	面积比率	失效标签	面积比率	失效标签	面积比率	失效标签
0.0000	-1	0.0000	-1	0.0000	-1	0.0000	-1
0.0000	-1	0.0000	-1	0.0000	-1	0.0000	-1
0.0000	-1	0.0000	-1	0.0000	-1	0.0000	-1
0.0000	-1	0.7860	1	0.0000	-1	0.0000	-1
0.1730	1	0.0730	-1	0.0000	-1	0.0000	-1
0.0000	-1	0.0000	-1	0.0000	-1	0.0000	-1
0.0000	-1	0.2000	1	0.0310	-1	0.0000	-1
0.0000	-1	0.0000	-1	0.0000	-1	0.0000	-1
0.7690	1	0.0000	-1	0.1290	-1	0.0000	-1
0.0000	-1	0.0000	-1	0.0000	-1	0.9800	1
0.0000	-1	0.1650	-1	0.4050	1	0.0000	-1
0.0000	-1	0.7980	1	0.0000	-1	0.0000	-1
0.0000	-1	0.0390	-1	0.0000	-1	0.1390	-1
0.0000	-1	0.0000	-1	0.1250	-1	0.0000	-1
0.0760	-1	0.0330	-1	0.0000	-1	0.0000	-1
0.0000	-1	0.1950	1	0.0000	-1	0.0740	-1
0.1350	-1	0.0000	-1	0.0000	-1	0.0240	-1
0.0000	-1	0.9570	1	0.0610	-1	0.0000	-1
0.0560	-1	0.9560	1	0.0000	-1	0.0000	-1
0.4720	1	0.0000	-1	0.0000	-1	0.0000	-1
0.7920	1	0.0000	-1	0.0000	-1	0.0000	-1
0.0220	-1	0.0000	-1	0.0000	-1	0.0000	-1
0.0000	-1	0.0000	-1	0.7580	1	0.0000	-1
0.0000	-1	0.0000	-1	0.0000	-1	0.0000	-1
0.0380	-1	0.0000	-1	0.0780	-1	0.0000	-1
0.0000	-1	0.0000	-1	0.1340	1	0.0000	-1
0.0000	-1	0.0000	-1	0.0000	-1	0.4650	1
0.1270	-1	0.2980	1	0.0730	-1	0.0000	-1
0.0000	-1	0.0650	-1	0.1090	-1	0.7720	1

对所得数据进行分析知，大量元器件并未发生失效，失效元器件数量为 802 组，正负样本比值约为 1:7，元器件失效特征样本数据存在分布不平衡的特征，故设计类别平衡调整比 $ri_{+,-}=7:1$ 。此外，在未失效样本中共有 4476 组未失效样本的标红区域的面积比率数值为 0，约占所有未失效样本总数的 80%，而这些样本所包含的失效信息很少，对分类器学习的帮助不大，因此下采样时主要保留失效元器件标红样本比率不为 0 的样本。随机选择 800 组正例样本，同时对失效样本进行下采样处理，随机选择 700 组标红区域面积比率不为 0 的失效样本，100 组标红面积比率为 0 的失效样本，平衡样本分布，见表 4.4。

表 4.4 平衡样本分布表（截取部分）

面积比 率	失效 标签	面积比 率	失效 标签	面积比 率	失效 标签	面积比 率	失效 标签	面积比 率	失效 标签
0.0290	-1	0.0000	-1	0.0240	-1	0.4760	1	0.4300	1
0.0430	-1	0.9260	1	0.2690	1	0.0480	-1	0.7510	1
0.0670	-1	0.0310	-1	0.0760	-1	0.0360	-1	0.4050	1
0.0480	-1	0.0670	-1	0.0000	-1	0.0700	-1	0.0300	-1
0.0000	-1	0.7400	1	0.0600	-1	0.9550	1	0.7580	1
0.9210	1	0.7120	1	0.0590	-1	0.4170	1	0.0410	-1
0.9500	1	0.9350	1	0.9650	1	0.1620	1	0.9700	1
0.9120	1	0.1160	1	0.0580	-1	0.0410	-1	0.2520	1
0.7170	1	0.6310	1	0.9330	1	0.0730	-1	0.0590	-1
0.0000	-1	0.0260	-1	0.0230	-1	0.1830	1	0.0330	-1
0.0740	-1	0.1580	1	0.0380	-1	0.4140	1	0.4410	1
0.0520	-1	0.0000	-1	0.4460	1	0.0000	-1	0.9470	1
0.2870	1	0.0500	-1	0.0700	-1	0.1070	1	0.2150	1
0.0330	-1	0.1510	1	0.0690	-1	0.0390	-1	0.0340	-1
0.0650	-1	0.1680	1	0.9480	1	0.4340	1	0.0010	-1
0.0610	-1	0.0640	-1	0.1770	1	0.0000	-1	0.0220	-1
0.9760	1	0.0620	-1	0.1430	1	0.0000	-1	0.0450	-1
0.0500	-1	0.0650	-1	0.0600	-1	0.1500	1	0.0690	-1
0.2520	1	0.9500	1	0.0390	-1	0.7700	1	0.0750	-1
0.0310	-1	0.1030	1	0.9910	1	0.0770	-1	0.7520	1
0.9050	1	0.4500	1	0.0650	-1	0.9310	1	0.0210	-1
0.0000	-1	0.0390	-1	0.4510	1	0.0710	1	0.0290	-1
0.9690	1	0.0200	-1	0.1640	1	0.7920	1	0.0580	-1
0.0260	-1	0.9780	1	0.2960	1	0.9910	1	0.0760	-1
0.4780	1	0.2290	1	0.0590	-1	0.0200	-1	0.0600	-1
0.0210	-1	0.0720	-1	0.4130	1	0.4950	1	0.0500	-1
0.0380	-1	0.4850	1	0.0320	-1	0.9990	1	0.0550	-1
0.4320	1	0.7500	1	0.0320	-1	0.7780	1	0.7080	1
0.9010	1	0.0370	-1	0.1650	1	0.0340	-1	0.7130	1
0.7160	1	0.0210	-1	0.0630	-1	0.0670	-1	0.4360	1
0.0370	-1	0.6250	1	0.4030	1	0.0000	-1	0.7160	1
0.0480	-1	0.0790	-1	0.2470	1	0.0280	-1	0.7370	1
0.4280	1	0.0500	-1	0.0720	-1	0.4500	1	0.0000	-1
0.0600	-1	0.1040	1	0.9260	1	0.0780	-1	0.9040	1
0.5000	1	0.7360	1	0.0410	-1	0.7570	1	0.0260	-1
0.0430	-1	0.2520	1	0.4350	1	0.0310	-1	0.9830	1
0.9980	1	0.1540	1	0.9180	1	0.0490	-1	0.0230	-1
0.9960	1	0.0780	-1	0.2140	1	0.0710	-1	0.0000	-1
0.5320	1	0.0300	-1	0.9910	1	0.9490	1	0.0570	-1
0.7920	1	0.0410	-1	0.0660	-1	0.0370	-1	0.9940	1

同时由于本文研究的塑封器件其应用环境为空间环境，这对元器件的可靠性要求严格，在实际的元器件筛选实验中，技术人员一般要求元器件发生失效的潜在几率尽可能

的低。因此，在于元器件进行失效判别时，其“误受”（第二类错误）的代价将要远高于“误拒”（第一类错误）的代价，故定义“误受”与“误拒”的代价比 $rc_{+, -} = 5:1$ 。根据代价比对元器件失效样本再次进行重采样操作。最终所得样本中有 800 组正例，160 组负例，处理结果见表 4.5。

表 4.5 元器件失效特征最终采样数据（截取部分）

面积比 率	失效 标签	面积比 率	失效 标签	面积比 率	失效 标签	面积比 率	失效 标签	面积比 率	失效 标签
0.0770	-1	0.9640	1	0.4410	1	0.1310	1	0.9380	1
1.0000	1	0.0150	1	0.4200	1	0.9710	1	0.9970	1
0.0680	-1	0.1880	1	0.0700	-1	0.2000	1	0.1880	1
0.2790	1	0.9390	1	0.2790	1	0.9130	1	0.4670	1
0.9930	1	0.4180	1	0.9260	1	0.0770	-1	0.2140	1
0.7140	1	0.0410	1	0.3810	1	0.9340	1	0.9390	1
0.0690	-1	0.9830	1	0.1900	1	0.4980	1	0.9770	1
0.1770	1	0.9900	1	0.7670	1	0.0520	-1	0.9830	1
0.1950	1	0.7870	1	0.9540	1	0.9700	1	0.4180	1
0.7240	1	0.2810	1	0.7040	1	0.9910	1	0.1790	1
0.9430	1	0.9530	1	0.1010	1	0.0740	-1	0.9680	1
0.7340	1	0.2590	1	0.0280	-1	0.1900	1	0.4650	1
0.9570	1	0.9260	1	0.1390	1	0.9800	1	0.7170	1
0.7400	1	0.4490	1	0.1930	1	0.1980	1	0.7670	1
0.0730	-1	0.7590	1	0.7810	1	0.9240	1	0.4470	1
0.9770	1	0.0260	-1	0.7580	1	0.9580	1	0.4450	1
0.1320	1	0.0770	-1	0.1750	1	0.1100	1	0.9330	1
0.0350	-1	0.9100	1	0.9910	1	0.9800	1	0.0290	1
0.0280	-1	0.2960	1	0.9120	1	0.2810	1	0.0610	-1
0.1180	1	0.7860	1	0.0970	1	0.4880	1	0.9980	1
0.1040	1	0.9690	1	0.0390	-1	0.9180	1	0.1580	1
0.1230	1	0.2080	1	0.1600	1	0.9040	1	0.7700	1
0.9250	1	0.7230	1	0.4630	1	0.9280	1	0.1500	1
0.9560	1	0.7840	1	0.4920	1	0.7460	1	0.0630	-1
0.4530	1	0.1470	1	0.9770	1	0.4650	1	0.0300	-1
0.4370	1	0.0530	-1	0.1140	1	0.9460	1	0.2920	1
0.0800	-1	0.9870	1	0.6550	1	0.9800	1	0.2050	1
0.9250	1	0.1800	1	0.9450	1	0.0580	-1	0.7290	1
0.1540	1	0.0520	-1	0.1260	1	0.0770	-1	0.9650	1
0.4320	1	0.9820	1	0.9150	1	0.4220	1	0.7750	1
0.2520	1	0.9190	1	0.9670	1	0.0360	-1	0.9480	1
0.9420	1	0.9780	1	0.2190	1	0.4030	1	0.9220	1
0.9020	1	0.0440	-1	0.9210	1	0.2910	1	0.1680	1
0.4850	1	0.1430	1	0.6730	1	0.2140	1	0.7800	1

4.3 基于机器学习的塑封元器件失效识别模型研究

元器件的失效判别，即对元器件是否失效进行分类。分类在数据挖掘研究领域是一

项十分重要的任务，它是一种典型的有监督机器学习方法，其目的是基于已知类别的训练数据样本作为输入，通过恰当的数据挖掘算法构建分类模型，将已经分类好的数据映射到指定的类别中，然后利用构建的分类模型去验证无类别标号的测试数据集。根据无类别标号的测试数据集分类的结果，评估分类模型的准确率。如果准确率可以接受，则认为该分类器可以应用于实际项目中。如果不能接受，则需要重新对训练样本进行分类，构造新的分类模型，在这个过程中可能需要更换其它有效的分类算法。最终从特定数据集的各个对象中提取出共有特性，以预测新数据的未知类别，并通过分类模型对其进行分类，进而获得重要数据的模型或预测未来的发展趋势。虽然目前新的分类方法层出不穷，但是每种分类方法都有其特定适用的领域。某一种方法不可能胜任所有的数据挖掘任务，通常在一个复杂的数据挖掘任务中往往会使用多种数据挖掘方法建立分类模型，以达到整合多种方法来弥补不同算法各自局限的目的。常用的数据挖掘分类方法有以下几种：贝叶斯分类、Logistic 回归、决策树、支持向量机、人工神经网络和集成学习等。

4.3.1 机器学习模型的选择

集成学习通过将多个弱学习器进行结合，可以获得比单一学习器显著优越的性能，且由 Hoeffding 不等式知，当基学习器的误差相互独立时，随着集成中个体分类器数目的增加，集成错误率将呈指数级下降，最终趋向于 0。实际的学习过程虽然并不满足上述假设，但是仍能通过增加基学习器的数目来提高学习器精度和泛化性能。而其集成学习是一种普适的方法，任何数据和学习器均能通过集成的方法来使其性能得到一定的提高。此外在最近的数据挖掘比赛中，集成学习已经成为一种十分常见的机器学习模型，几乎每届比赛的冠军均使用了集成学习的方法。因此，对于本文中输入数据为一维的简单二分类问题，可以尝试使用集成学习来进行分类。

SVM 支持向量机是对数据分类的一种十分常见的方法，该方法在上世纪末得到了广泛的研究和使用。研究表明支持向量机具有较好的鲁棒性，对于模型参数不需要过多的调整，计算简单，时间成本低，且具有完整的理论体系，与其他分类模型相比有较好的可解释性等优点，尤其是对低维数据的二分类问题，SVM 支持向量机总是属于一种性能优越的分类器。故本文尝试使用 SVM 支持向量机对塑封器件超声波扫描图片失效特征数据进行学习、分类。

目前深度学习在机器学习中是一个异常火热的领域，而深度学习依赖的模型算法即

为神经网络。本文中对塑封元器件失效图片的识别虽然并未使用深度学习的方法，但仍就有必要对应用广泛的神将网络进行讨论分析。神经网络是机器学习中的主流算法之一，各种不同连接方式、不同损失函数和激活函数的网络模型层出不穷，本文选择几种常见的神经网络如 GRNN 广义回归神经网络、PNN 概率神经网络、RBF 神经网络等对元器件超声波扫描图片失效特征进行识别分类。

综上，本文选择集成学习、SVM 支持向量、常用的神经网络三种不同类型的学习模型对元器件超声波扫描图片失效特征进行识别分类，并比较、分析、讨论各个分类器的综合性能。

4.3.2 集成学习 AdaBoost 识别失效元器件

集成学习 (Ensemble Learning) 是一种机器学习的范式，它通过结合多个 (一般是同质的) 弱学习器来解决同一个问题，集成学习可以有效地提高学习系统的泛化能力。

集成学习通过训练多个算法并将其结果以某种方式进行组合，从而达到提高模型泛化能力的目的。用来训练的算法可以是相同的 (同质)，也可以是不同的 (异质)。目前国内国外大多数的研究主要集中在相同算法的集成上。这是因为不同的算法其学习机理不同，因此很难用统一的标准来衡量它们的准确度，而且采用不同的算法后集成学习的复杂度将增加^[89]。通过集学习能提高预测结果的稳定性和准确性，较好的解决模型训练中过拟合问题。同时集成学习通过建立多个不同参数的学习模型，并将其按照一定的方式进行集成，能在一定程度上避免机器学习中参数调优的难题。

集成学习领域经过十余载的发展，已由最初的萌芽而逐渐发展壮大，国内外学者都提出了许多各种不同的算法，其中以 Boosting 和 Bagging 方法影响最为广泛。事实上，Bagging 和 Boosting 是目前集成学习中研究最深入的两个算法族，这两种算法都是通过改变训练样本来构造集成学习算法，但是这两种算法也均有各自不同的理论体系。

1. Boosting 算法

Boosting 算法于 1990 年由 Freund 和 Schapire 首次提出^[90]，其理论依据源于 PAC (Probably approximately correct) 学习模型。Boosting 是一种能够提升任何给定学习算法精度的普适方法。目前也已经存在多种改进的 Boosting 算法，在众多算法中最具有代表性的应是 Freund 和 Schapire 于 1996 年提出了 AdaBoost 算法，即自适应 Boosting 算法 (Adaptive Boosting)。该算法的原理是使用弱学习算法生成一系列的弱分类器，每个弱分类器的训练将依赖于上一次分类器的分类结果，弱分类器在训练集上

的错误率将被用于调整训练样本的概率分布。同时，每个训练样本均被赋予一个权重，代表相应样本被选入某个弱分类器训练集的概率。如果某样本没有被正确分类，那么它的权值就将被提高，在构造下一个训练集时，它的权值将增加，其被选中作为训练集的概率将升高；反之，如果某个样本已被正确分类，那么它的权值就降低，其被选中的概率将减小。通过 AdaBoost 算法对每一次训练的结果进行提升，最终形成一系列的弱分类器，通过单个弱分类器的加权投票得到最终分类器，并以此来提高弱分类器的分类性能。

2. Bagging 算法

Breiman 于 1996 年提出了与 Boosting 类似的 Bagging 算法^[91]。Bagging 算法的基本思想为重复取样，它通过对样本进行重复采样获得训练集，每次迭代都随机地从大小为 n 的原始训练集中抽取 m 个样本作为训练的集合。这种训练集被称为原始训练集合的 Bootstrap 复制，故这种方法也叫 Bootstrap，即 Bagging。Bagging 通过重新选取训练集增加了分布并行学习器集成的差异度，从而提高了模型的泛化能力。Breiman 指出，Bagging 集成的原算法的稳定性是 Bagging 能否提高预测准确率的关键因素。Bagging 对不稳定的学习算法预测准确度有较大的提升，而对于稳定的学习算法效果则并不十分明显，有时甚至会使预测精度降低。与 Boosting 相比 Bagging 对训练集的选择是随机的，各轮训练集之间相互独立，而 Boosting 对训练集的选择并不独立，各轮训练集的选择与前面各轮的学习结果有关。此外，Bagging 的各个预测函数没有权值，而 Boosting 带有权值。Bagging 的各个预测函数并行生成，而 Boosting 的各个预测函数只能顺序的串行生成。因此，对于像神经网络这样极为耗时的学习方法，Bagging 可通过并行训练大幅降低时间成本。

本文采用文献[[92]]设计的 AdaBoost 算法。AdaBoost 的算法流程主要为：训练数据中的各个样本，并为其赋予一个权值，这些样本权值将组成向量 D 。同时初始化一个弱分类器，假设该弱分类器的权值为 α ，训练弱分类器，然后根据分类错误率 ϵ 对分类器权值 α 进行调整。同时综合弱分类器对各个样本的分类结果，对样本权值向量 D 进行调整。正确分类的样本权值将减小，而错误分类的样本权值将增加。接下来在相同的训练集上再次训练一个弱分类器，并对样本权值向量 D 进行调整，同时依据分类错误率计算出该分类器的权值 α 。如此反复，直至分类错误率为 0 或训练弱分类器数目达到指定数目算法停止。其流程图如图 4.2 所示。

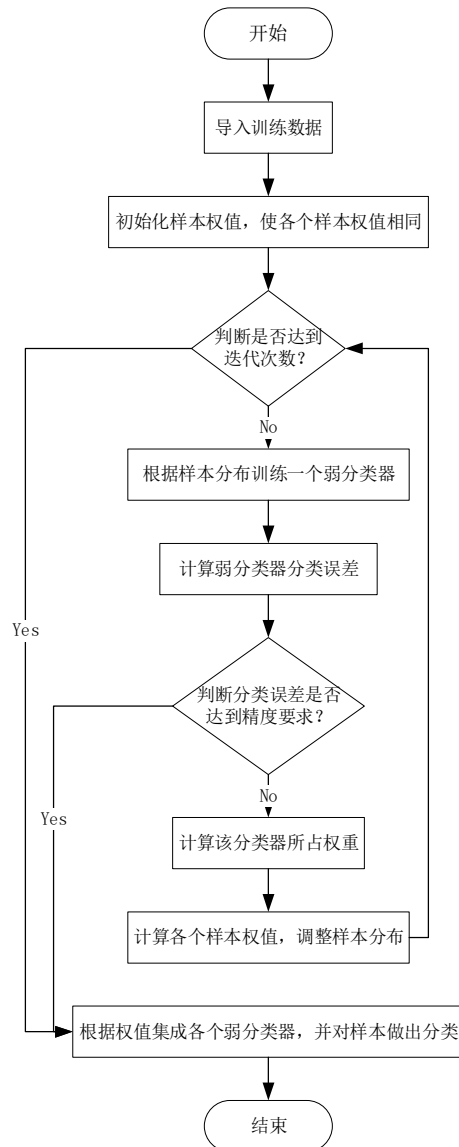


图 4.2 AdaBoost 算法流程图

Step1. 记训练集个样本权值向量 $D = \{\omega_1, \omega_2, \dots, \omega_n\}$ ，初始化样本权值向量 D ，其中 $\omega_1 = \omega_2 = \dots = \omega_n = \frac{1}{n}$ 。

Step2. 训练一个弱分类器 h_k ，同时计算该弱分类器的分类误差 ε ，
$$\varepsilon = \frac{\text{未正确分类的样本数}}{\text{总样本数}}。$$

Step3. 根据弱分类器 h_k 分类误差 ε ，计算该分类器所占权值 α_k ，
$$\alpha_k = \frac{1}{2} \ln \left(\frac{1 - \varepsilon}{\varepsilon} \right)。$$

Step4. 根据分类器 h_k 所占权值 α 对第 k 轮迭代的各个样本权值 ω_i^k 进行调整：

若在第 k 轮迭中，样本 i 被正确分类则其权值 ω_i^k 调整为：
$$\omega_i^k = \frac{\omega_i^{k-1} e^{-\alpha_k}}{\text{Sum}(\omega_i)}。$$

若在第 k 轮迭中，样本 i 未被正确分类则其权值 ω_i^k 调整为：
$$\omega_i^k = \frac{\omega_i^{k-1} e^{\alpha_k}}{\text{Sum}(\omega_i)}。$$

Step5. 反复迭代，直至训练错误率小于要求精度或迭代次数即弱分类器数目达到指定数目为止。

Step6. 对各个弱分类器 h_k 进行集合，得到样本最终的分类结果 H ，其中

$$H(x) = \text{sign} \left(\sum_{k=1}^m \alpha_k h_k(x) \right)。$$

由于本论文参考国军标设计的塑封器件超声波扫描图片失效特征仅为描述子为图片中标红区域所占面积比率，模型的输入数据维数为 1，因此对于 C4.5 决策树等一些较为复杂的分类方法在此并不适用。此外由于集成学习算法最初的研究目标是针对弱学习器而言，故本文选择最简单的决策树分类器，单层决策树（决策树桩）进行集成学习。利用 Python3.6 编写算法

本文中利用经过综合平衡化处理后的元器件特征数据训练分类器，采用留出法随机选择 760 组样本作为训练集训练分类器，将另外 200 组数据作为测试集测试分类器的综合性能。其中 AdaBoost 共集成 40 个弱分类器，并分别对原始数据、样本平衡化数据和综合采样数据进行训练，并对结果进行分析比较。其结果如表 4.6 所示。

表 4.6 各数据集综合性能表					
数据集	训练时间 /s	ROC 包围面 积 AUC	查准率 P	查全率 R	分类错误率 ϵ
综合采样处理	0.142975	0.990946	1	0.9940828	0.025
原始数据集	0.358094	0.997110	0.975155	0.969136	0.015385
样本平衡化	0.171481	0.995025	1	0.918239	0.003125

观察表 4.6 知，对比数据集发现原始数据集程序运行时间为 0.358s，约为采样数据的 2.5 倍。经过下采样后数据样本减少为原来的 1/7，同时训练时间明显缩短。对比原始数据集，虽然样本平衡化数据集其 ROC 包围面积 AUC 略小，但是其 ROC 曲线有交叉，无法准确判断哪个分类器孰好孰坏。此外，样本数据平衡化处理后其查准率和分类错误率有明显提高，因此可以认为样本平衡化对分类器综合性能的提升有一定的帮助。综合采样处理是在样本平衡化处理的基础上考虑分类误差代价的敏感性，对样本再次下采样处理。对比三组样本数据，可以明显看出虽然综合采样处理数据集分类错误率与另外两

者相比较高,但在样本分布不平衡和代价敏感的情况下,该指标无明显参考价值。然而,综合采样处理数据集其查准率与查全率均最高,因此在代价敏感和样本分布不平衡的条件下,综合采样处理效果最为理想。




图 4.3 各样本数据集集成学习 ROC 曲线

观察图 4.3 可知,各样本数据集训练所得的分类器性能均较高,其 ROC 曲线均集中在左上角区域。但是各个分类器的 ROC 曲线均有交叉且各 ROC 曲线包围面积数值相差较小,因此单单根据 ROC 曲线比较各样本数据集的好坏较难有很强的说服力。

4.3.3 支持向量机识别失效元器件

支持向量机(Support Vector Machine, SVM)是由 Vapnik 等人于 20 世纪 90 年代中期提出的一种基于统计学习理论的通用学习算法。该算法的主要思想是针对二分类问题而言。通过在高维空间中寻找一个超平面对两类样本进行分割,以保证最小的分类误差,同时使结构风险最小化 (Structure Risk Minimization, SRM)。SVM 方法主要适合于解决高维、非线性的二分类问题,同时由于其本质思想与传统学习方法的区别,其能有效避免经典学习方法中维数灾难、局部极小、过学习和欠学习的缺陷。同时由于该方法具有较好的泛化性能,其在解决分类、回归和密度估计等问题时表现出许多独有的优势,而且分类准确性要好于传统的决策树等分类方法,因而该方法被认为是目前解决小样本分类、回归等问题的最佳方法^[93]。

支持向量机的原理是:在二次规划问题中,支持向量机试图寻找一个满足在正类和负类之间最优、最大边缘间隔的分类超平面对样本进行分割,使得不但保证分类的精度,

而且能使超平面两侧的空白区域最大。从理论上分析可知，支持向量机可以实现对线性可分数据的最优分类，同时在解决非线性分类问题时，通过引入核函数的方法将低维空间映射至高维空间，降低维空间数据线性不可分问题转化为高维空间线性分类问题，从而利用原有的线性分类算法寻找最优分割超平面。由于该方法需要通过核函数进行映射。因此，支持向量机在核函数的选取和构造等方面均有大量的研究。

（1）支持向量机的结构与理论基础

支持向量是由算法从训练数据中抽取的小的子集而构成。“支持向量” $x(i)$ 和输入空间抽取向量 x 之间的内积核是构造支持向量机学习算法的关键所在。其体系结构如下所示。




图 4.4 支持向量机体系结构

其中 K 为核函数，其种类主要有：

线性核函数： $K(x, x_i) = x^T x_i$ ；

多项式核函数： $K(x, x_i) = (\gamma x^T x_i + \gamma)^p, \gamma > 0$ ；

径向基核函数： $K(x, x_i) = \exp(-\gamma \|x - x_i\|^2), \gamma > 0$ ；

两层感知器核函数： $K(x, x_i) = \tanh(\gamma x^T x_i + \gamma)$ 。

本文塑封器件超声波扫描图片失效判别为二分类问题，故这里选择二分类支持向量机。

C-SVC 模型是比较常见的二分类支持向量机模型，其算法流程具体如下所述：

Step1. 设已知训练集：

$$T = \{(x_1, y_1), \dots, (x_l, y_l)\} \in (X \times Y)^l \quad (4.12)$$

Step2. 选取适当的核函数 $K(x, x')$ 和适当的参数 C ，构造并求解最优问题：

$$\begin{aligned} \min & \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j \alpha_i \alpha_j K(x_i, x_j) - \sum_{j=1}^l \alpha_j \\ \text{s.t.} & \sum_{i=1}^l y_i \alpha_i = 0, \quad 0 \leq \alpha_i \leq C, i=1, \dots, l \end{aligned} \quad (4.13)$$

得到最优解： $\alpha^* = (\alpha_1^*, \dots, \alpha_l^*)^T$ 。

Step3. 选取 α^* 的一个正分量 $0 < \alpha_j^* < C$ ，并据此计算阈值：

$$b^* = y_i - \sum_{i=1}^l y_i \alpha_i^* K(x_i - x_j) \quad (4.14)$$

Step4. 构造决策函数：

$$f(x) = \text{sgn} \left(\sum_{i=1}^l \alpha_i^* y_i K(x, x_i) + b^* \right) \quad (4.15)$$

(2) 利用支持向量机判别元器件失效

为大致比较各类算法的综合性能，在此选择与集成学习中相同的训练集与测试集样本对支持向量机进行训练。此外，为使最终的预测结果有较高的稳定性和保真性，这里选择 10 次 10 折交叉训练的方法，并分别比较在高斯 RBF 核函数、多项式核函数和线性核函数上分类器的性能。利用 MATLAB2014a 编写程序代码。最终分类器综合性能如表 4.7 所示。

表 4.7 不同核函数下支持向量机性能对比

核函数	训练时间/s	查准率	查全率	分类错误率 ϵ
Gaussian RBF (sigma=0.04)	0.003332	1	0.9942	0.0050
多项式核函数	0.002082	1	0.9711	0.0050
线性核函数	0.002071	1	0.9884	0.0010

对比各种核函数下支持向量机的各个性能指标，可以明显发现 Gaussian 核函数其各项指标性能最佳，线性核函数相比较差。这也在一定程度上反映出塑封器件超声波扫描图片失效识别是线性不可分问题。

4.3.4 神经网络识别失效元器件

人工神经网络(Artificial Neural Network, ANN)最初是由心理学家和神经学家开

创，通过利用计算机来进行神经系统的模拟和开发。它由大量简单处理的单元按照某种方式相互连接而成，其中每个连接都对应一个权值，靠其对外部输入信息的动态响应来处理信息^[94]。人工神经网络用以模拟生物大脑的功能和结构，是在生物神经网络研究的基础上，根据生物神经元和神经网络的特点，通过简化归纳提炼总结出来的一类并行信息处理系统。

简单的来说，神经网络就是一组相互连接的输入输出单元，其中每个连接都拥有一个权重值与其对应，在每次学习的过程中，算法不断调整这些权值，使其能够正确的预测类别标号。人工神经网络算法同时也是一种非常好的函数逼近算法，万能逼近定理（Hornik et al., 1989; Cybenko, 1989）已经证明：一个含有单独隐含层的神经网络结构，如果给定充分的神经元，那么这个神经网络可以以任意精度逼近任意函数。目前以出现大量改进的神经网络算法，例如 BP、RBF、PNN、GRNN 等等。对此本论文比较几种常见的神经网络在元器件超声波扫描图片缺陷识别上的性能。

1. 广义回归神经网络

广义回归神经网络（Generalized Regression Neural Network, GRNN）是由美国学者 Donald F. Specht 在 1991 年提出的，它属于径向基神经网络的一种。GRNN 具有很强的非线性映射能力、柔性网络结构以及高度的容错性和鲁棒性，其适用于解决非线性问题。GRNN 在学习速度和逼近能力上较 RBF 网络有更加明显的优势，网络最后将收敛于样本量积聚较多的优化回归面，并且在样本数据较少时，也能取得较好的预测效果。此外，GRNN 还能处理不稳定的数据。因此，其在信号过程、控制决策系统、教育产业、结构分析、食品科学、金融领域、能源、药物设计、生物工程等各个领域均得到了广泛的应用。

GRNN 在结构上与 RBF 网络十分相似。它是由四层结点构成，如下图所示，分别为输入层(input layer)、模式层(pattern layer)、求和层(summation layer)和输出层(output layer)。对应网络输入为 $X = [x_1, x_2, \dots, x_n]^T$ ，输出为 $Y = [y_1, y_2, \dots, y_n]^T$ 。




图 4.5 广义回归神经网络结构

a. 输入层

输入层直接将输入变量传递给模式层，其神经元数目等于学习样本中输入向量的维数，各个神经元是简单的分布单元。

b. 模式层

模式层神经元数目等于学习样本的数目 n ，各神经元对应不同的样本，模式层神经元传递函数为

$$p_i = \exp \left[\frac{(X - X_i)^T (X - X_i)}{2\sigma^2} \right] \quad i = 1, 2, \dots, n \quad (4.16)$$

神经元 i 的输出为输入变量与其对应样本 X 之间 *Euclid* 距离的平方指数 $D^2 = (X - X_i)^T (X - X_i)$ 。式中， X 为网络输入变量； X_i 为第 i 个神经元对应的学习样本。

c. 求和层

求和层中使用两种神经元进行求和。

一类计算公式为 $\sum_{i=1}^n \exp \left[-\frac{(X - X_i)^T (X - X_i)}{2\sigma^2} \right]$ ，它对所有模式层神经元的输出进行

算术求和，其模式层与个神经元的连接权值为 1，传递函数为：

$$S_D = \sum_{i=1}^n P_i \quad (4.17)$$

另一类计算公式为 $\sum_{i=1}^n Y_i \exp \left[-\frac{(X - X_i)^T (X - X_i)}{2\sigma^2} \right]$ ，它对所有模式层神经元进

行加权求和，模式层中第 i 个神经元与求和层中第 j 个分子求和神经元之间的连接权值

为第 i 个输出样本 Y_i 中的第 j 个元素，传递函数为

$$S_{Nj} = \sum_{i=1}^n y_{ij} P_i \quad j=1,2,\dots,k \quad (4.18)$$

d. 输出层

输出层中的神经元数目等于学习样本中输出向量的维数 k ，各神经元将求和层的输出相除，神经元 j 的输出对应估计结果 $\hat{Y}(X)$ 的第 j 个元素，即

$$y_i = \frac{S_{Nj}}{S_D} \quad j=1,2,\dots,k \quad (4.19)$$

广义回归神经网络的理论基础为非线性回归分析。非独立变量 Y 相对于独立变量 x 的回归分析本质上是计算具有最大概率值的 y 。设随机变量 x 与随机变量 y 的联合概率密度函数为 $f(x, y)$ ，若已知 x 的观测值为 X ，则 y 相对于 X 的回归，也即条件均值为

$$\hat{Y} = E(y/X) = \frac{\int_{-\infty}^{\infty} y f(X, y) dy}{\int_{-\infty}^{\infty} f(X, y) dy} \quad (4.20)$$

\hat{Y} 即为在输入为 X 的条件下， Y 的预测输出。

1962 年 *Parzen* 提出了一种从已知的随机样本中估计概率密度函数的方法。经理论分析知只要样本数目足够多，该方法所获得的函数可以连续平滑地逼近原概率密度函数。

通过 *Parzen* 非参数估计，可由样本数据集 $\{x_i, y_i\}_{i=1}^n$ ，估算密度函数 $\hat{f}(X, y)$ 。

$$\hat{f}(X, y) = \frac{1}{n(2\pi)^{\frac{p+1}{2}} \sigma^{p+1}} \sum_{i=1}^n \exp\left[-\frac{(X-X_i)^T (X-X_i)}{2\sigma^2}\right] \exp\left[-\frac{(Y-Y_i)^2}{2\sigma^2}\right] \quad (4.21)$$

式中， n 为样本容量； p 为随机变量 x 的维数； X_i, Y_i 为随机变量 x 和 y 的样本观测值； σ 为高斯函数的宽度系数，也称为光滑因子。

用 $\hat{f}(X, y)$ 代替 $f(X, y)$ 带入上式，并交换积分与加和顺序可得：

$$\hat{Y}(X) = \frac{\sum_{i=1}^n \exp\left[-\frac{(X-X_i)^T (X-X_i)}{2\sigma^2}\right] \int_{-\infty}^{+\infty} y \exp\left[-\frac{(Y-Y_i)^2}{2\sigma^2}\right] dy}{\sum_{i=1}^n \exp\left[-\frac{(X-X_i)^T (X-X_i)}{2\sigma^2}\right] \int_{-\infty}^{+\infty} \exp\left[-\frac{(Y-Y_i)^2}{2\sigma^2}\right] dy} \quad (4.22)$$

由于 $\int_{-\infty}^{+\infty} ze^{-z^2} dz = 0$ ，对两个积分进行计算后可得网络的输出 $\hat{Y}(X)$ 为

$$\hat{Y}(X) = \frac{\sum_{i=1}^n Y_i \exp \left[-\frac{(X - X_i)^T (X - X_i)}{2\sigma^2} \right]}{\sum_{i=1}^n \exp \left[-\frac{(X - X_i)^T (X - X_i)}{2\sigma^2} \right]} \quad (4.23)$$

估计值 $\hat{Y}(X)$ 为所有样本观测值 Y_i 的加权平均，每个观测值的权重因子为相应的样本 X_i 与 X 之间 *Euclid* 距离平方的指数。当光滑因子 σ 非常大时， $\hat{Y}(X)$ 近似于所有样本因变量的均值。相反，当光滑因子 σ 趋向于 0 时， $\hat{Y}(X)$ 和训练样本非常接近，当需预测的点被包含在训练样本集中时，公式求出的因变量的预测值会和样本中对应的因变量非常接近，而一旦碰到样本中未能包含的点，该模型的预测效果有可能会非常差，这种现象说明网络的泛化能力较差。当 σ 取值适中时，所有训练样本的因变量都将被考虑，与预测点距离较近的样本点对应的因变量将获得更大的权值。

同样选择与上文中相同的训练样本，利用 10 次 10 折交叉训练对网络进行训练，利用测试样本评价网络模型的性能。其中 Spread 取值为 0.1。模型的测试结果如下表所示。

表 4.8 广义回归神经网络测试性能				
网络名称	训练时间/s	查准率	查全率	分类错误率
广义回归神经网络	10.9311	1	0.9942	0.0050

通过上表能清楚看出自组织竞争神经网络分类错误率较低查准率和查全率均较高，仅有一个样本识别错误，该神经网络效果较好。

2. 概率神经网络

概率神经网络 (probabilistic neural networks , PNN) 由 D. F. Spech 博士于 1989 年首先提出，其是一种基于 Bayes 分类规则与 Parzen 窗的概率密度面数估计方法发展而来的并行算法。具有结构简单、训练简洁、应用广泛的特点。在实际应用，尤其是在分类问题中，PNN 的优势在于利用线性学习算法替代非线性学习算法，同时保持非线性算法的高精度等特性；该网络对应的权值就是模式样本的分布，网络不需要训练，因而能够满足实时处理的要求。

PNN 网络是由径向基函数网络发展而来的一种前馈型 PNN 神经网络，其理论依据为

贝叶斯最小风险准则（即贝叶斯决策理论），PNN 作为径向基网络的一种，适用于模式分类。当分布密度 SPREAD 的值接近于 0 时，它退化为最邻分类器；当 SPREAD 的值较大时，它构成对几个训练样本的临近分类器。PNN 层次模型，由输入层、模式层、求和层、输出层共 4 层组成，其基本结构如下图所示。




图 4.6 概率神经网络结构图

输入层接收训练样本，并将特征向量传递给网络。其神经元数目和样本矢量的维数保持一致。模式层神经元的个数等于各个类别训练样本数之和，其主要功能为计算输入特征向量与训练集中各个模式的匹配关系。该层每个模式单元的输出为

$$f(X, W_i) = \exp \left[-\frac{(X - W_i)^T (X - W_i)}{2\delta^2} \right] \quad (4.24)$$

式中， W_i 为输入层与模式层的连接权值； δ 为平滑因子，该值的大小对分类起着至关重要的作用。

第 3 层为求和层，是将属于某类的概率进行累计，按上式计算，从而得到故障模式的估计概率密度函数。其中每一类只有一个求和层单元，求和层单元与只属于自己类的模式层单元相连接，而与模式层中的其它单元没有连接。因此求和层单元简单地将属于自己类的模式层单元的输出相加，而与属于其他类别的模式层单元的输出无关。求和层单元的输出与各类基于内核的概率密度的估计值成比例，通过输出层的归一化处理，就可得到各类的概率估计。

网络输出的决策层由简单的阈值辨别器构成，其作用是在各个故障模式的估计概率密度中选择一个具有最大后验概率密度的神经元作为整个系统的输出。输出层神经元是

一种竞争神经元，每个神经元分别对应于一个数据类型即分类类别，输出层神经元个数等于训练样本数据的种类数目，它接收从求和层输出的各类概率密度函数，概率密度函数最大的那个神经元输出为 1，即所对应的那一类为待识别的样本类别，其他神经元的输出均为 0。

基于 PNN 的分类方法是概率统计学中被广泛接受的一种决策方法，可描述为：假设有两种已知的类别 θ_A, θ_B ，对于要判断的特征样本 $X = (x_1, x_2, \dots, x_n)$ ：

若 $h_A l_A f_A(X) > h_B l_B f_B(X)$ ，则 $X \in \theta_A$ ；

若 $h_A l_A f_A(X) < h_B l_B f_B(X)$ ，则 $X \in \theta_B$ ；

式中， h_A 、 h_B 为分类类别的 θ_A 、 θ_B 先验概率 ($h_A = N_A / N, h_B = N_B / N$)； N_A 、 N_B 为分类类别的 θ_A 、 θ_B 的训练样本数； N 为训练样本总数； l_A 为将本属于 θ_A 的特征样本 X 错误地划分到模式 θ_B 的代价因子； l_B 为将本属于 θ_B 的特征样本 X 错误地划分到模式 θ_A 的代价因子； f_A 、 f_B 为分类类别 θ_A 、 θ_B 的概率密度函数 (Probability Density Function, PDF) 通常 PDF 不能精确地获得，只能根据现有的类别特征样本求其统计值。

由 *Parzen* 方法得到的 PDF 估计式如下：

$$f_A(X) = \frac{1}{m(2\pi)^{\frac{p}{2}} \delta^p} \sum_{i=1}^m \exp \left[-\frac{(X - X_{ai})^T (X - X_{ai})}{2\delta^2} \right] \quad (4.25)$$

式中， X_{ai} 为故障模式 θ_A 的第 i 个训练向量； m 为故障模式 θ_A 的训练样本数目； δ 为平滑因子，其取值确定了以样本点为中心的钟状曲线的宽度。

选择与上文中相同的训练样本，利用 10 次 10 折交叉训练对网络进行训练，利用测试样本评价网络模型的性能。其中分布密度 SPREAD 的值取 0.009。概率神经网络的分类结果如**错误!未找到引用源。**所示。




图 4.7 概率神经网络分类结果

表 4.9 概率神经网络测试性能

网络名称	训练时间/s	查准率	查全率	分类错误率
概率神经网络	1.5006	1	0.9942	0.0050

结合表 4.9 和图 4.7，可以看出概率神经网络有较好的性能。

3. RBF 神经网络

生物神经学中中枢神经元的感受视野是指能影响某一神经元反映的视野或视网膜区域。视网膜上的光感受器通过接受光并将其转化为输出神经信号，从而不同程度的激活众多神经节细胞和视觉皮层中的神经细胞。RBF 神经网络就是通过模拟视网膜的感受功能而形成的，其基本特性如下：

- ①距离感受野中心越近，视神经元越兴奋；距离感受野中心越远，视神经元越消极。
- ②视神经元的激活区域呈现镜像对称。

将上述生物视野感受原理映射到 RBF 网络，可以用以下函数对隐含神经元进行建模：

$$\varphi_i(x) = G\left(\frac{\|x - T_i\|}{\sigma_i}\right) \quad (4.26)$$

式中， x 为输入样本； $G(\bullet)$ 为径向基函数，也即激活函数、激励函数或传递函数； σ 为宽度，其决定了径向基函数围绕中心点的宽度； T_i 为感受视野中心即中心点； $\|x - T_i\|$ 是距离函数，表示的是网络样本值与数据中心（中心点）间的距离； $\varphi_i(x)$ 为网络输出。隐含神经元径向基函数一般选用 Gaussian 函数，上述神经元对应的模型即可转化为：

$$\varphi_i(x) = \exp\left(-\frac{\|x - T_i\|^2}{\sigma_i^2}\right) \quad (4.27)$$

梯度训练法 RBF 网络有三层结点，隐含层激活函数为高斯函数，第一层和第三层都是线性传递函数，本网络采用梯度下降法反向调整网络误差。根据链式求导法则，可得网络数据中心、宽度和权值的调整量分别为：

$$\begin{aligned}
\Delta c_i &= \eta_1 \frac{w_i}{\sigma_j^2} \sum_{j=1}^N e_j G(x_j) (x_j - T_i) \\
\Delta \sigma_i &= \eta_2 \frac{w_i}{\sigma_j^3} \sum_{j=1}^N e_j G(x_j) \|x_j - T_i\|^2 \\
\Delta w_i &= \eta_3 \sum_{j=1}^N e_j G(x_j)
\end{aligned} \tag{4.28}$$

上式中, G 表是高斯函数; i, j 分别是隐节点数量和样本数量的下标; w 为权值, η_1, η_2, η_3 分别表示各自学习的速率; e 表示样本值与网络输出值之间的残差。

RBF 网络隐含层由激活函数神经元与距离函数构成, 越靠近数据中心的样本越可能被更大程度的激活, 越偏离数据中心的样本, 网络对其响应程度越小。

RBF 神经网络的构建过程如下所示。

Step1. 监督学习方法训练算法步骤。

初始化: 对原始数据 x 进行归一化处理, 随机指定隐层与输出层连接权重 w_i , 函数的中心 T_i , 预置允许误差, 预置学习步长 η_1, η_2, η_3 , 宽度 σ_i 的值;

Step2. 循环, 直至达到允许误差或指定重复次数。

$$\textcircled{1} \text{ 计算 } e_j, j=1, 2, \dots, N, \quad e_j = d_j - f(X_j) = d_j - \sum_{i=1}^M w_i \cdot G(X_j, T_j)$$

$$\textcircled{2} \text{ 计算输出单位权重的改变量: } \frac{\partial E(n)}{\partial w_i(n)} = -\frac{1}{N} \sum_{j=1}^N e_j \exp\left(\frac{-\|x_j - T_i\|^2}{2\sigma_i^2}\right)$$

$$\text{改变权重, } w_i(n+1) = w_i(n) - \eta_1 \frac{\partial E(n)}{\partial w_i(n)}$$

$$\textcircled{3} \text{ 计算隐单元中心的改变量: } \frac{\partial E(n)}{\partial T_i(n)} = -\frac{w_i}{N\sigma_i^2} \sum_{j=1}^N e_j \exp\left(\frac{-\|x_j - T_i\|^2}{2\sigma_i^2}\right) \cdot (X_j - T_i)$$

$$\text{改变中心, } T_i(n+1) = T_i(n) - \eta_2 \frac{\partial E(n)}{\partial T_i(n)}$$

$$\textcircled{4} \text{ 计算函数宽度的改变量: } \frac{\partial E(n)}{\partial \sigma_i(n)} = -\frac{w_i}{N\sigma_i^2} \sum_{j=1}^N e_j \exp\left(\frac{-\|x_j - T_i\|^2}{2\sigma_i^2}\right) \cdot (\|X_j - T\|^2)$$

$$\text{改变宽度, } \sigma_i(n+1) = \sigma_i(n) - \eta_3 \frac{\partial E(n)}{\partial \sigma_i(n)}$$

⑤计算误差： $E = \frac{1}{2N} \sum_{j=1}^N e_j^2$

选择与上文中相同的训练样本，利用 10 次 10 折交叉训练对网络进行训练，利用测试样本评价网络模型的性能。

表 4.10 RBF 神经网络测试性能

网络名称	训练时间/s	查准率	查全率	分类错误率
概率神经网络	4.3788	1	0.9942	0.0050




图 4.8 神经网络训练误差曲线

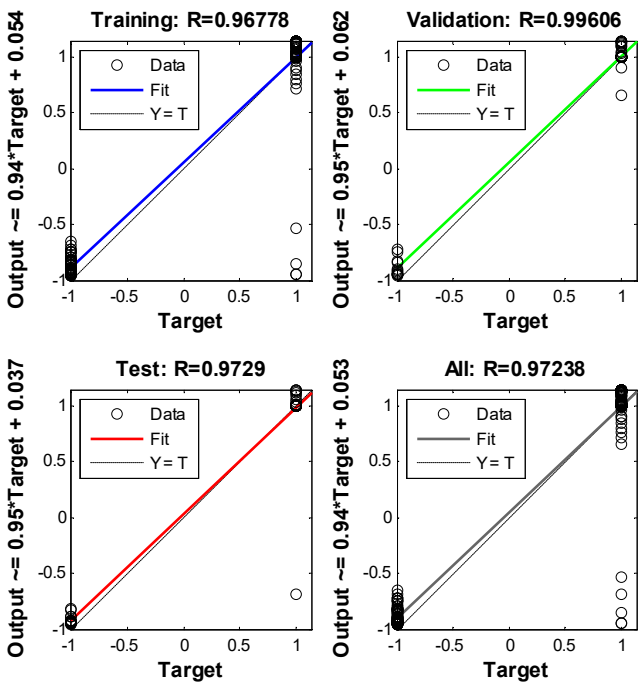


图 4.9 神经网络回归线

结合表 4.10 以及图 4.8 神经网络的训练误差收敛图和图 4.9 回归线图,可以看出，

模型在第 5 次迭代后误差已经收敛为以极小值，通过模型的回归线图可以看出其测试集和训练集样本回归线均位于对角线附近，模型没有过拟合现象的发生。表 4.10 中记录模型的查准率和查全率均较高且判别误差值较小，因此可以认为该模型性能较优。

4.4 各失效元器件识别模型性能的比较

除上述讨论的识别模型为，本文还选择了 Logistic 回归模型和其它几种常见的神经网络如 LVQ 学习向量量化神经网络、自组织神经网络。本文设计 LVQ 网络的神经元数目为 15，迭代次数为 50 次，学习率为 0.01，学习函数为 learnlv1 权值学习函数，训练目标最小误差 0.1。自组织神经网络学习速率为 0.1，迭代次数为 20 次，竞争层神经元数目即分类数目为 2。网络的训练样本和测试样均保持与上文一致，训练方法为 10 次 10 折交叉训练。最终各分类器的综合性能如下表所示。

表 4.11 各分类器性能表

分类器名称	训练时间/s	查准率	查全率	分类错误率
AdaBoost	0.171481	1	0.918239	0.003125
SVM (rbf 核函数)	0.003332	1	0.9942	0.0050
SVM(多项式核函数)	0.002082	1	0.9711	0.0050
SVM(线性核函数)	0.002071	1	0.9884	0.0010
GRNN 广义回归神经网络	10.9311	1	0.9942	0.0050
PNN 概率神经网络	1.5006	1	0.9942	0.0050
LVQ 学习向量量化神经网络	479.6765	0.8650	1	0.1350
RBF 神经网络	4.3788	1	0.9942	0.0050
自组织竞争神经网络	90.0101	1	0.7052	0.2550
Logistic 回归	0.016541	0.8693	1	0.13

观察表 4.11 可知，自组织神经网络由于其学习方式为非监督竞争型学习，在学习过程中没有借助先验知识对学习过程进行监督校正，因此该网络的预测精度且鲁棒性最差，但是其查准率却因此而得到了提高。由于 Logistic 回归分类器是一种较为简单的分类器，其在元器件超声波扫描图片失效识别中，将所有的样本全预测为正类，故查全率为 1，但是在实际应用中，该分类器已经失去了任何价值。LVQ 学习向量量化神经网络其查全率为 1，但是综合性能较差且训练时间成本较长，不适合对塑封器件超声波扫描图片进行失效识别。对比上述 10 种方法，与预期设想较为相符，集成学习由于其集合了多个弱学习器，因此其识别效果较为理想泛化性好。SVM 凭借其本身原理上的优势，在塑封器件超声波扫描图片失效识别这种简单的二分类问题中，无论在时间成本上还是识别精度上均表现出了良好的性能。此外在神经网络中 GRNN 广义回归神经网络、PNN 概率神经网络、RBF 神经网络也都有不错的性能表现。相较而言，Logistic 线性回归、LVQ 学习向量量化神经网络、自组织竞争神经网络这些分类器性能并不理想。因

此在实际应用中,可以考虑采用集成学习或 SVM 支持向量机对元器件超声波扫描显微图片进行失效识别。

4.5 本章小结

由于本文研究塑封器件应用于高可靠领域,故对其进行失效判别时“误拒”和“误受”的风险代价并不一致,因此该机器学习类型为代价敏感学习。此外对元器件超声波扫描显微图片失效特征提取数据进行分析,发现大部分样本元器件均未发生失效,而关注的失效器件属于小样本,样本分布存在一定的不平衡性。综合分析结果可知,本文机器学习研究的对象为小样本本代价敏感学习,对此本文结合代价敏感和样本平衡的处理方法,计算综合调整比对样本数据进行预处理。同时利用集成学习 AdaBoost 方法分析了不同数据分布和不同代价下的分类器性能。比较知,对样本进行分布平衡和下采样后,分类器查准率、查全率均有所提高。

此外,本章还比较了不同分类器的综合性能,并重点分析了不同核函数 SVM 支持向量机和 GRNN、PNN、RBF 常见神经网络的分类结果。分析各分类器的性能可知 SVM 支持向量机、集成学习以及一些常见的神经网络均有不错的分类精度。综合考虑,可以选择将 SVM 支持向量机用于最后的塑封器件超声波扫描图片的失效识别中。

5 塑封元器件声扫失效图像识别工具的实现

根据前文工作，本章利用 MATLAB 编写图形用户界面（GUI），开发塑封器件声扫失效图像识别工具，将多个元器件超声波扫描图片预处理、分割、保存，潜在失效元器件超声波扫描图片的筛选，单张元器件超声波扫描显微图片的形态学处理、标红区域面积比率的计算、失效类型的确定、失效特征的提取，以及根据失效特征调用优化后的识别模型对元器件是否失效等功能集成于一个用户界面中，并通过人机交互的方式将各中工能展现出来，以减轻技术人员的操作不便和理解负担。同时识别工具的开发也使得本论文的有关工作更具有现实意义和实际价值。

5.1 塑封元器件超声波扫描图片读取功能



图 5.1 塑封器件超声波扫描图片读取界面

塑封器件超声波扫描图片读取界面如图 5.1 所示，通过点击右侧 load image 按钮，技术人员可以选择元器件超声波扫描图片的路径，并将其读取至窗口界面中。

5.2 塑封元器件超声波扫描图片分割、保存功能

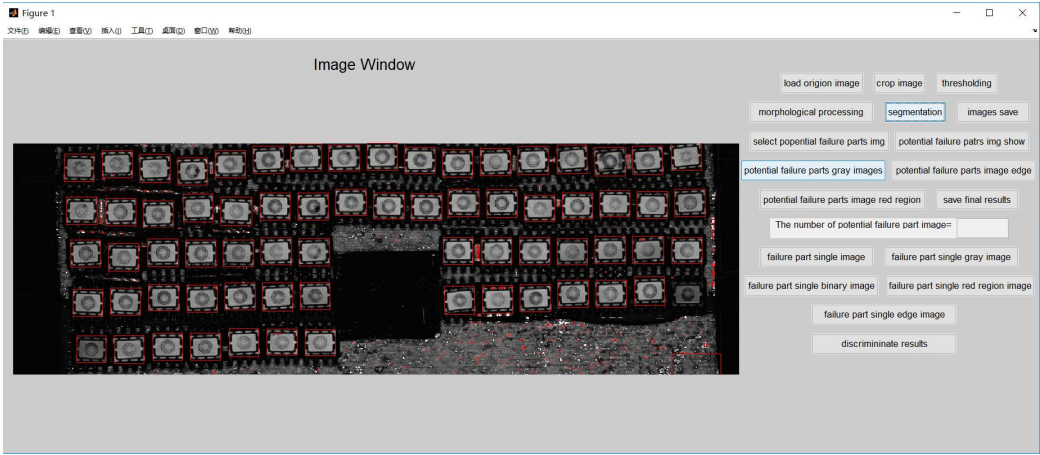


图 5.2 塑封器件超声波扫描图片分割

点击右侧 segmentation 按钮，可以完成对塑封器件超声波扫描图片的分割操作，继续点击 save the images，该界面将自动保存经过分割后的每个塑封器件超声波扫描显微图片于指定路径中。

5.3 潜在失效元器件超声波扫描图片筛选、保存功能

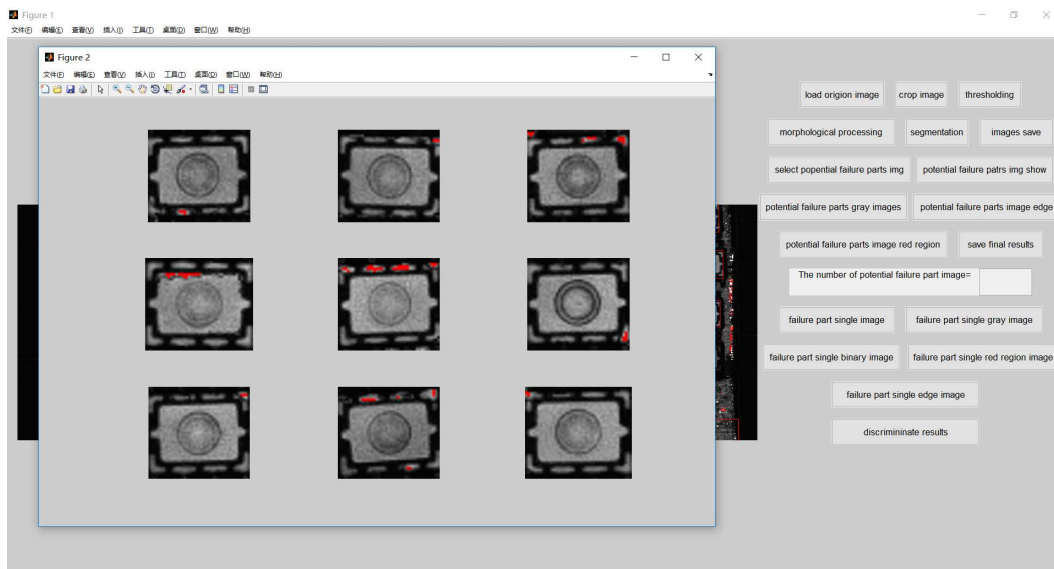


图 5.3 潜在失效元器件筛选功能

通过上个步骤完成对塑封器件超声波扫描图片的分割，接下来点击右侧 select 按钮，可以完成对塑封器件潜在失效元器件的筛选，并将筛选结果显示在子图中。观察上图，可以看出一共筛选出 9 张潜在失效元器件超声波扫描图片，这些元器件均存在较大面积的标红区域且标红区域位于极易发生失效处。

5.4 单张塑封器件超声波扫描图片查看功能




图 5.4 单张塑封器件超声波扫描图片查看

在图形界面的右侧 failure part image 文本框中输入上述筛选出的潜在失效元器件超声波扫描图片的编号，可以查看对应的塑封元器件扫描图片。例如，在文本框中输入 5，便可以查看编号为 5 的元器件超声波扫描显微图片，如图 5.4 所示。

5.5 单张塑封器件超声波扫描图片处理功能



图 5.5 单张塑封器件超声波扫描图片处理

通过对潜在失效元器件扫描图片的选择查看，点击右侧 binary image 按钮可以查看潜在失效元器件的二值图，此外点击 extract edge 按钮可以提取出失效元器件的边界，点击 gray image 按钮可以查看超声波扫描图片的灰度图，点击 red region 可以查看扫描图片的标红区域等等。

5.6 元器件失效特征的提取与、保存与失效判别

在 5.3 小结中介绍了潜在失效塑封器件超声波扫描图片的筛选功能，在点击右侧 select failure images 按钮时本界面已经完成了对扫描图片失效特征的提取过程，因此接下来点击 save results 按钮时，即可选择路径保存失效特征数值结果。最后点击 image recognition 按钮，调用上文中训练完毕的分类器对塑封器件进行失效判别，最后将结果保存至指定文件中。

5.7 本章小结

本章对元器件超声波扫描显微图片失效识别工具进行说明，分别介绍了塑封器件扫描图像的读取、分割、潜在失效元器件扫描图片的筛选、查看、特征提取和失效识别的功能。通过自主识别工具完成对元器件超声波扫描的判别失效，大大减轻了技术人员的认知负担，同时人机间的友好交互也使得本论文的相关工作具有较大的应用价值。

6 结论与展望

本文对图像识别技术在塑封器件超声波扫描显微镜检领域中的应用进行了研究分析。首先调研了塑封器件在航天领域中的应用情况及发生失效的类型和应对措施。总结了目前塑封器件超声波扫描显微镜检技术存在的问题以及图像识别技术在超声波扫描检测交叉领域的应用情况。其次介绍了超声波扫描检测的原理和扫描模式以及塑封器件分层失效的类型和原因。然后设计元器件失效特征描述子，通过图像处理技术对超声波扫描图片进行分割和特征提取。接下来本文分析了元器件失效特征数据，并通过综合调整的方法对代价敏感且类别不平衡的特征数据进行下采样处理。同时利用一些常见的分类模型对元器件进行失效判别。最后根据上述工作成果编写失效识别工具，实现塑封器件超声波扫描显微图片失效识别的人机交互功能。

6.1 工作总结

本文的主要结论如下：

1. 塑封器件应用于航天领域存在较大的失效风险，超声波扫描显微镜检技术是避免元器件发生失效保证空间任务顺利开展的有效手段。目前的超声波扫描检测技术效率低、识别准确率差、大量依赖技术人员知识经验且存在“误拒”的风险。图像识别技术应用于塑封器件超声波扫描显微检测域，目前国内外均没有相关的研究工作，因此本论文具有一定的创新性和实际的应用价值。
2. 塑封器件封装分层是常见的失效形式，而引线架界面分层在封装分层失效中占比最大。超声波扫描显微镜检技术能够有效判别塑封器件分层失效。
3. 图像识别技术能够对塑封器件超声波扫描显微图片进行有效分割。参考国军标等技术手册，根据标红区域形心坐标将元器件失效类型划分为三类：引线架界面分层；引线引出端焊板与模塑化合物界面分层；两处均发生分成。设计标红区域面积比率这一失效特征描述子能够较好判别元器件是否失效。
4. 提取出的元器件失效特征描述数据存在代价敏感和样本分布不平衡的特点。通过综合调整比对数据进行下采样处理能够较好的提升分类器的查准率、查全率和综合性能。AdaBoost 集成学习分类器、SVM 支持向量机和 PNN 概率神经网络、GRNN 广义回归神经网络对塑封器件超声波扫描显微图片失效识别均有较好的效果。
5. 开发塑封元器件超声波扫描图像失效识别工具，将上述过程中对图像的处理、

识别过程以图形交互界面的方式进行展现,这使得本文的相关工作更具现实意义和商用价值。

6.2 工作展望

目前国内外对与塑封器件失效模式和失效机理的研究已经取得了大量有价值 and 意义的成果。而对于机器学习研究领域,各种不同思想的算法模型也层出不穷,将图像识别技术应用于工业和实际生活中的案例也比比皆是。尤其是近年来深度学习的迅猛发展,如何利用机器学习技术更好的改变生活服务社会,这一问题引起了学术界、工业界等各个学科领域的广泛讨论和高度重视。对于利用机器学习技术识别失效塑封器件超声波扫描图片这一研究方向,本文首次做出了简单的探索,并取得了一些初步的结论。在本文的研究内容和研究方向上有以下一些问题仍需进一步探究。

1. 在元器件的失效识别中,本文分别对三种元器件的失效类型进行了讨论,并对不同的失效类型分别设计机器学习模型进行识别。该工作过程较为繁琐,在进一步的研究中,可以通过设计元器件失效特征描述子,将不同的失效类型进行区分。如本文中完全可以将标红区域的相对形心坐标作为另一种样本特征,与标红区域面积比率这一特征相结合构成特征向量训练识别模型,将原来的二分类问题拓展为多分类问题,即不仅判别元器件是否失效,还可以得到元器件的失效类型,通过增加模型复杂度使其能够解决更复杂的问题。

2. 本文对塑封器件超声波扫描图片失效识别的探究工作是基于传统的机器学习方法,即通过特征工程手工设计的特征失效描述子来训练模型,实现元器件的失效识别。在如今深度学习“红的发展”的研究背景下,本文进一步可以尝试使用端到端的训练方式对塑封器件超声波扫描图片进行失效识别。该方法依赖大量的失效元器件超声波扫描图片,需要进行长时间的样本收集和积累工作。

3. 本文目前只对一种封装类型的元器件超声波扫描图片失效识别进行了深入的研究,对于其它封装类型的元器件超声波扫描图片失效识别,是否可以利用迁移学习的方法或思想来设计和训练模型。同时,能否将机器学习技术应用于其他的元器件筛选试验,如 X-射线扫描检测、电子显微镜扫描检测的显微图像失效识别中。这些也将是一个值得深入研究的方向。

4. 在元器件超声波扫描图像失效特征的提取过程中,对图像的处理有多种操作方法可以进行尝试。如标红区域面积比率的计算和修正工作,就存在多种处理的思路和方法

法。

5. 本文中塑封元器件超声波扫描失效图像识别工具的实现功能较为简单，在进一步的研究中，可以对其开发和集成更多的功能。例如，对图像的剪裁操作，该工具不仅可以实现自动剪裁的功能，还能通过手动框选裁剪区域，对元器件的剪裁区域实现自主可控。

参 考 文 献

- [1] Pecht, M. G. Nguyen, L. T. and Hakim, E. R., Plastic Encapsulated Microelectronics[J]. Wiley, New York, 1995.
- [2] J.Huang and D. Yang. Discriminating Defects Method for Plastics Encapsulated Microcircuits by Using Scanning Acoustic Microscope[C], Prognostics and System Health Management Conference IEEE, China: Chengdu, 2016: 1-6.
- [3] Esteve M, Perez-Llopis I, Palau C E. Friendly force tracking COTS solution[J]. Aerospace and Electronic System Magazine, 2013, 28(1): 14-21.
- [4] Edward B. Why use PEMs in military equipment: users' response[J]. Journal of Microelectronics Reliability, 1998, 3, 28:403-407.
- [5] Michael C Maher, Can. COTS Products Be Used in Radiation Enviroments[J]. Journal of COTS, 2003, 11.
- [6] Behr P, Rwald W B, Briess K, et al. Fault tolerance and COTS: next generation of high performance satellite computers. Aerospace Conference[C], German: Fraunhofer, 2003:532.
- [7] Barnard A, Nwosa C. COTS based on –board-computer on South Africa's sumbandilass: A radiation and in-or-bit performance analysis. Radiation Effects Data Workshop (REDW)[C]. USA: New York. 2011: 1-4.
- [8] Urwin M J, Oldfield M K. The design and operation of a COST space GPS receiver[J]. Advances in the Astronautical Sciences, 2000, 104: 465-473.
- [9] T Sterling, D Becker, T Cwik. An assessment of Beowulf-class computing for NASA requirements: initial findings from the first NASA workshop on Beowulf-class clustered computing[C]. Aerospace Conference, 1998, 4: 367-381.
- [10] Hua Gengxin, Wang Guoling, Guo Shuling. Radiation hardening techniques for on-board computers[J]. Aeros. Cont, 2003, 21(1): 10-15.
- [11] Sun Huixian. The Chinese scientific satellite “Practice-5” payloads[J], In: 33rd COSPAR Scientific Assembly, 2000.
- [12] Kayail S. Utilization of COTS electronics in space application, reliability challenges and reality[C]. 6th International CMSE Conference, 2002.

- [13] Mike Sandor. Plastic Encapsulated Microcircuits (PEMs) Reliability/ Usage Guidelines For Space Applications[J]. Office 514 Electronic Parts Engineering D-19426, Jet Propulsion Laboratory California Institute of Technology, Pasadena, California, 2000, 20: 104-182.
- [14] Alexander Tevenrovsky, Kusum Sahu. NASA/TP-2003-212244, PEM-INST-001[S]. Instructions for Plastic Encapsulated Microcircuit (PEMS) Selection, Screening and Qualification, 2003.
- [15] Mecluskey, P. et al, Plastic Encapsulated Microelectronics: materials, process, quality, reliability and applications[J], John Wiley & Son: 15-17, 1995.
- [16] TR Oldham, FB Mclean, Total ionizing dose effects in MOS oxides and devices[J], IEEE Transactions on Nuclear Science, 2003, 50: 483-499.
- [17] Duzellier, R Ecoffet, Recent trends in single-event effect ground testing[J] IEEE Transactions on Nuclear Science, 1996, 43: 671-677.
- [18] Shu T.Lai. Some Space Hazards of Surface Charging and Bulk Charging[J]. Space Vehicles Directorate. Air Force Research Laboratory.
- [19] C.O'Connor, P.McCluskey, Guidebook on the Use of PEMs at High Altitude[B], University of Maryland, 2008.
- [20] Gerke R D, Sandor M, Agawal S, et al. Different Approaches for Ensuring Performance Reliability of Plastic Encapsulated Microcircuits (PEMs) in Space Applications[J], 2000.
- [21] S. Brand, et al, 9D-6 Signal Analysis in Scanning Acoustic Microscopy for Non-Destructive Assessment of Connective Defects in Flip-Chip BGA Devices[J], 2007, 817-820.
- [22] J. Nagalingam, S. D. Mohd-Yusoff, P. Ramakrishnan, R. Jaafar. Scanning acoustic microscope (SAM)-a measurement tool for plastic IC packages[J], International Symposium on Physical & Failure Analysis of Integrated Circuits, 2007, 244-249.
- [23] FAN X J,SHUIR E. Moisture sensitivity of plastic packages of IC devices[J], USA: New York, 2010, 168-177.
- [24] H. Hashimoto, S. Tanaka, & Sato, K. Silicon acoustic lens for scanning acoustic microscope (SAM)[C], International Conference on Solid-State Sensors and Actuators, Digest of Technical Papers, Transducers, 1991, 853 – 859.
- [25] 军用电子元器件破坏性物理分析方法[S], GJB4027A-2006, 中国人民解放军总装备部, 2006.

- [26] 微电子器件试验方法和程序[S], GJB548B-2005, 中国人民解放军总装备部, 2005.
- [27] MIL-STD-1580B, Destructive Physical Analysis for Electronic, Electromagnetic, and Electromechanical Parts[S].
- [28] PEM-INST-001, Instructions for Plastic Encapsulated Microcircuit (PEM) Selection, Screening, and Qualification.
- [29] 元器件筛选技术条件[S], QJB 103A-2010, 中国航天科工集团公司标准, 2010.
- [30] Sollie, G., Ultrasound Transmission Tomography: A Low-Cost Realization [D], Eindhoven University of Technology, Netherlands, 1988.
- [31] 白净. 医学超声成像机理[D]. 北京: 清华大学出版社, 1998.
- [32] Quate C.F., Atalar A., Wickramasinghe H.K. Acoustic microscopy with mechanical scanning-A review[J]. Proceedings of the IEEE, 1979, 67: 1092-1114.
- [33] Chen H., Zuo M.J., Wang X., Hoseini M.R. An adaptive Morlet wavelet filter for time-of-flight estimation in ultrasonic damage assessment[J]. Measurement, 2010,43: 570-585.
- [34] Huang J, Yang D. Discriminating defects method for plastic encapsulated microcircuits by using scanning acoustic microscope[C], Prognostics and System Health Management Conference. IEEE, 2017:1-6.
- [35] Chen Y, Li P. The common failure mechanisms of plastic encapsulated devices induced by package defect[C], International Conference on Electronic Packaging Technology and High Density Packaging. IEEE, 2011:1-3.
- [36] Liang Y, Zhang S. A case study of the delamination analysis of plastic encapsulated microcircuits based on scanning acoustic microscope inspection[C], Prognostics and System Health Management Conference. IEEE, 2014:190-193.
- [37] Qiu Y, Zhang S. Study on the pin delamination of plastic encapsulated microcircuits using scanning acoustic microscope[C], Prognostics and System Health Management Conference. 2017:1-5
- [38] G.Kamalaakar, Mukesh Kumar, S.GiridharRao, Non-Destructive Evaluation of Electronic Components for Aerospace Application[J]. Advanced Systems Laboratory, DRDO, India: Hyderabad.
- [39] Mario P, Josef M, Michael I. Inverted high frequency Scanning Acoustic Microscopy inspection of power semiconductor devices[J]. Microelectronics Reliability, 2012, 52(9-10):2115-2119.

- [40] Liu L, packaging devices in combination reliability test[C]. International Conference on Electronic Packaging Technology. 2017:231-234. Li E, Luo X, et al. Study on delamination variation trend of two plastic
- [41] 陈章涛, 潘凌宇. 声学扫描显微镜检查在塑封器件检测中的应用[J]. 电子与封装, 2013(3):9-12.
- [42] Good M.S., Wend C.F., Bond L-J McLean J.S., Panetta P.D., Ahmed S., Crawford, S.L., Daly D.S. An estimate of biofilm properties using an acoustic microscope[J]. IEEE Transactions on Ultrasonics, Ferroelectrics, and Frequency Control, 2006, 53(9): 1637-1648.
- [43] Raum K., Jenderka K.V, Klemenz A., Brandt J. Multilayer analysis: quantitative scanning acoustic microscopy for tissue characterization at a microscopic scale[J]. IEEE Transactions on Ultrasonics, Ferroelectrics, and Frequency Control, 2003, 50(5): 507-516.
- [44] Tohmyoh H., Akanda M.A.S. Sensitivity of acoustic microscopy for detecting three-dimensional nanometer gaps embedded in a silicon structure[J]. Journal of Acoustical Society of America, 2009, 126: 98-102.
- [45] Tohmyoh H., Suzuki M. Measurement of the coating thickness on the back side of double-sided coated structures by means of acoustic resonant spectroscopy[J]. Surface & Coatings Technology, 2009, 204: 546-550.
- [46] Tohmyoh H, Imaizumi T, Saka M. Acoustic resonant spectroscopy for characterization of thin polymer films[J]. Review of Scientific Instruments, 2006, 77(10):407.
- [47] Deneuville F, Duquennoy M, Ouafthouh, et al. High frequency ultrasonic detection of C-crack defects in silicon nitride bearing balls.[J]. Ultrasonics, 2009, 49(1):89.
- [48] Kannajosyula S P, Chillara V K, Balasubramaniam K, et al. Simultaneous measurement of ultrasonic longitudinal wave velocities and thicknesses of a two layered media in the absence of an interface echo[J]. Review of Scientific Instruments, 2010, 81(10):105101.
- [49] 杨克己. 基于神经网络的检测声学信号处理理论与实践[D], 浙江大学博士论文, 1997.
- [50] Qin S, Omar M, Shan D. Ultrasonic NDE Techniques for Impact Damage Inspection on CFRP Laminates[J]. Journal of Materials Science Research, 2011, 1(1).
- [51] Wu C C, Lee W L, Chen Y C, et al. Ultrasonic liver tissue characterization by feature fusion[J]. Expert Systems with Applications, 2012, 39(10):9389-9397.

- [52] D’Orazio T, Distanto A, Pianese V, et al. Automatic ultrasonic inspection for internal defect detection in composite materials[J]. Ndt & E International, 2008, 41(2):145-154.
- [53] Sambath S, Nagaraj P, Selvakumar N. Automatic Defect Classification in Ultrasonic NDT Using Artificial Intelligence[J]. Journal of Nondestructive Evaluation, 2011, 30(1):20-28.
- [54] Zhang G M, Zhang C Z, Harvey D M. Sparse signal representation and its applications in ultrasonic NDE[J]. Ultrasonics, 2012, 52(3):351-63.
- [55] Kumar A. Computer-Vision-Based Fabric Defect Detection: A Survey[J]. IEEE Transactions on Industrial Electronics, 2008, 55(1):348-363.
- [56] Kumar A, Pang G K H. Defect detection in textured materials using Gabor filters[J]. IEEE Transactions on Systems Man & Cybernetics Part B Cybernetics A Publication of the IEEE Systems Man & Cybernetics Society, 2002, 32(5):553-70.
- [57] Ohtsu N. A Threshold Selection Method from Gray-Level Histograms[J]. IEEE Transactions on Systems Man & Cybernetics, 1979, 9(1):62-66.
- [58] Ng H F. Automatic thresholding for defect detection[J]. Pattern Recognition Letters, 2006, 27(14):1644-1649.
- [59] Lee H T, Wang M, Maev R, et al. A study on using scanning acoustic microscopy and neural network techniques to evaluate the quality of resistance spot welding[J]. International Journal of Advanced Manufacturing Technology, 2003, 22(9-10):727-732.
- [60] Fan M, Su L, Li L, et al. A fuzzy SVM for intelligent diagnosis of solder bumps using scanning acoustic microscopy[C]// Semiconductor Technology International Conference. IEEE, 2016:1-3.
- [61] 李晓云,张之圣,曹俊峰. 环氧树脂在电子封装中的应用及发展方向[J].电子元件与材料,2003,22(2):36-37.
- [62] S.Atkins, L.Teems, W.Rowe, et al. Use of C-SAM acoustical microscopy in package evaluation and failure analysis[J], Microelectronics Reliability, 1998, 38(5):773-785.
- [63] 宋寿鹏,阙沛文. 超声信号的非线性行为及应用[J].传感技术学报,2007,20 (1) :128-131.
- [64] Kyungyoung Jhang, Hyoseong Jang, Byungil Park, etal. Wavelet Analysis Based Deconvolution to Improve the Resolution of Scanning Acoustic Microscope Images for the Inspection of Thin Die Layer in Semiconductor [J]. NDT&E International, 2002,35: 549–557.

- [65] G. Vogg, T. Heidmann, S. Brand. Scanning Acoustic GHz-microscopy Versus Conventional SAM for Advanced Assessment of Ball Bond and Metal Interfaces in Microelectronic Devices [J]. Microelectronics Reliability, 2015, 55: 1554–1558.
- [66] 刘平. 假冒电子元器件的识别与分析[J]. 电子元件与材料, 2012, 31 (2): 59-60.
- [67] 黄莉. 基于激光电子散斑技术的 IC 芯片封装热可靠性分析系统研究[D]. 桂林: 桂林电子科技大学, 2009.
- [68] 周鹏, 蒋廷彪, 农红密. PBGA 封装的耐湿热可靠性试验研究[J]. 半导体技术, 2009-10: 942-945.
- [69] Fan Mengying , Wei Li , He Zhenzhi, et al. Defect Inspection of Solder Bumps Using the Scanning Acoustic Microscopy and Fuzzy SVM Algorithm[J], Microelectronics Reliability, 2016, 65: 192–197.
- [70] S. Oberhoff, K. Goetz, K. Trojan, et al. Application of High Frequency Scanning Acoustic Microscopy for the Failure Analysis and Reliability Assessment of MEMS Sensors [J], Microelectronics Reliability, 2016, 64: 656–659.
- [71] Mario P, Josef M, Michael I. Inverted high frequency Scanning Acoustic Microscopy inspection of power semiconductor devices[J]. Microelectronics Reliability, 2012, 52(9–10): 2115-2119.
- [72] Viola P, Jones M. Fast and Robust Classification using Asymmetric AdaBoost and a Detector Cascade[J]. Advances in Neural Information Processing Systems, 2001, 14: 1311–1318.
- [73] Person R, Goney G, Shwaber J. Imbalanced clustering for microarray times-series. In: Proceedings of the ICML'03 Workshop on Learning from Imbalanced Data Sets[C]. Washington, DC, 2003.
- [74] Wu G, Chang E Y. Class-boundary alignment for imbalanced dataset learning. In: Proceedings of the ICML'03 Workshop on Learning from Imbalanced Data Sets[C]. Washington, DC, 2003.
- [75] Wu J, Mullin M D, Rehg J M. Linear asymmetric classifier for cascade detectors[C]. In: Proceeding of the 22nd International Conference on Machine Learning, Bonn, Germany, 2005, 993-1000.
- [76] He H, Garcia E A. Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering[J]. 2009, 21(9): 1263-1284.

- [77] Turney P D. Cost-Sensitive Classification: Empirical Evaluation of a Hybrid Genetic Decision Tree Induction Algorithm[J]. Journal of Artificial Intelligence Research, 1995, 2(1): 369-409.
- [78] Ling C X, Yang Q, Wang J N, et al. Decision Trees with Minimal Costs[C]. Proceedings of the Twenty-First International Conference on Machine Learning, New York, NY, USA, 2004: 69-76.
- [79] Domingos P. MetaCost: A General Method for Making Classifiers Cost. Sensitive[C]. Proceedings of the fifth ACM SIGKDD international conference on Knowledge discovery and data mining, New York, NY'USA, 1999, 155-164.
- [80] Chai X Y, Deng L, Yang Q, et al. Test-Cost Sensitive Naïve Bayesian Classification[C]. Proceedings of the Fourth IEEE International Conference on Data Mining, Washington, DC, USA, 2004: 51-58.
- [81] Zadrozny B, Langford J, Abe N. Cost-Sensitive Learning by Cost-Proportionate Example Weighting[C]. Proceedings of the 3th International Conference on Data Mining, Washington, DC, USA, 2003: 435-442.
- [82] Ting K M. Inducing Cost-Sensitive Trees via Instance Weighting[C]. Proceedings of the Second European Symposium on Principles of Data Mining and Knowledge Discovery, London, UK, 1998: 139-147.
- [83] Ting K M. An empirical study of metacost using boosting algorithms[M]. Springer Berlin Heidelberg, 2000.
- [84] 乔玉龙, 潘正祥, 孙圣和. 一种改进的快速 k-近邻分类算法[J]. 电子学报, 2005, 33(6): 1146-1149.
- [85] Lusa L. SMOTE for high-dimensional class-imbalanced data[J]. BMC bioinformatics, 2013, 14(1): 1-16.
- [86] Chawla N V, Cieslak D A, Hall L O, Joshi A, Automatically countering imbalance data sets[J]. ACM SIGKDD Explorations, 2004, 6(1), 1-6.
- [87] Witten I H, Frank E. Data Mining: Practical Machine Learning Tools and Techniques with Java Implementations, 2nd edition. Morgan Kaufmann, San Francisco, CA, 2005.
- [88] Faundez-Zanuy M. On the Usefulness of Almost-Redundant Information for Pattern Recognition[M]// Nonlinear Speech Modeling and Applications. Springer Berlin Heidelberg, 2005: 357-364.

- [89] 梁英毅 . 集成学习综述 [EB/OL]. <http://soft.cs.tsinghua.edu.cn/keltin/docs/ensemble.pdf>. 2006.
- [90] Freund Y, Schapire R. E. A decision-theoretic generalization of on-line learning and an application to boosting[J]. Journal of computer and system sciences, 1997, 55(1): 119-139.
- [91] Hansen L K, Salamon P. Neural network ensembles. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1990, 12(10): 993-1001.
- [92] Freund Y, Schapire R. E. A decision-theoretic generalization of on-line learning and an application to boosting[J]. Journal of computer and system sciences, 1997, 55(1): 119-139
- [93] Cherkassky V. The Nature Of Statistical Learning Theory[J]. IEEE Transactions on Neural Networks, 1997, 8(6):1564.
- [94] 陈安, 陈宁. 数据挖掘技术及应用[M]. 科学出版社, 2006.